Avances en la Línea de investigación: Motor de aumentación de prompt modelos de IA generativos

Dr. Martin Becerra [1], **Dr. Jorge Ierache** [1,2], **Mg. Pablo Soligo** [2], **Ing. Diego Sanz** [1]
[1] **Universidad Nacional de La Matanza, DIIT, Grupo de Investigación de Realidad Aumentada e Inteligencia Artificial Aplicada (RAIA)**
[2] **Universidad Nacional de La Matanza, DIIT, Grupo de Investigación y Desarrollo de Software Aeroespacial (GIDSA)**
Florencio Varela 1903, La Matanza, Buenos Aires, Argentina
{mabecerra, jierache}@unlam.edu.ar

Resumen

Se presentan en este trabajo los avances de la línea de investigación dedicada a explorar el desarrollo de framework para la asistencia, creación de prompts e integración de datos para modelos IA generativa. El framework busca facilitar la aplicación de técnicas de aumentación de prompts en aplicaciones potenciadas por modelos de lenguaje (LLMs).

Palabras clave: Modelos generativos, Grafos de conocimiento (Knowledge graphs), Frameworks, Modelos de Lenguajes

Contexto

La investigación presentada es desarrollada por el Grupo de Investigación de Realidad Aumentada e Inteligencia Artificial Aplicada del Departamento de Ingeniería e Investigaciones Tecnológicas de la Universidad Nacional de La Matanza en el marco del proyecto PROINCE C256: Framework para explotación de modelos de IA generativos multimodales.

Introducción

En la actualidad se han logrado varios avances en modelos de lenguaje de Inteligencia artificial que mejoraron los modelos GPT 3 y 4[1] , ChatGPT[2], Llama2[3] y Gemini[4] aplicados a tareas de propósito general multimodales (Ejemplo: texto, imágenes, video, y razonamiento estadístico). Deepseek logró con sus modelos V3[5] y R1[6] que el costo de entrenamiento se reduzca considerablemente lo que permite tener capacidades similares a sistemas GPT y modelos grandes con modelos más pequeños. Esto generó un gran impacto en la industria y en la investigación para poder replicar resultados obtenidos por Deepseek[7].

La evolución de IA generativa, muestra una gran capacidad para modelar el lenguaje, sin embargo presentan inconvenientes, una de ellos que por generar palabras estadísticamente estos modelos generativos dependen fuertemente del prompt inicial ofrecido por el usuario para que se obtengan los resultados deseados. Otro inconveniente, derivado del anterior, es que estos modelos sufren de alucinaciones[8], en otras palabras el modelo devuelve datos que no corresponden al prompt enviado por el usuario. Para abordar el primer inconveniente surgió la disciplina ingeniería de prompts[9] que busca estudiar los diferentes patrones de prompts y técnicas para incorporar conocimiento externo que permiten alcanzar mejores resultados. Para el segundo, se encuentra una técnica propuesta por facebook llamada Retrieval augmented generation (RAG)[10], que permite integrar hechos fácticos / datos desde base de datos y/o Grafos de conocimiento (Knowledge graphs)[11] en la inferencia del modelo generativo (Large Language model, LLM) [12], esta estrategia tiene como desventaja que es compleja de llevar a cabo correctamente.

Por lo tanto, bajo la creciente tendencia de creación de nuevas técnicas para generar prompts tales como chain of thoughts[13], a tree of thoughts[14] y Multimodal chain-of-

thought[15] e integrar hechos fácticos mediante para extender el conocimiento de un LLM es cada vez más complejo mediante técnicas tales como RAG [10] y GraphRAG[16] integrar estos enfoques en aplicaciones para ingenieros sin conocimientos técnicos, en particular en Procesamiento de Lenguaje Natural (NLP) y modelado de conocimiento.

Líneas de Investigación, Desarrollo e Innovación

La línea de investigación y desarrollo se lleva adelante bajo el marco del proyecto PROINCE C-256: Motor de aumentación de prompt modelos de IA generativos.

El objetivo de esta línea de investigación aplicada es continuar la línea propuesta en [17] es el desarrollo de un motor para reducir la complejidad de desarrollo de aplicaciones potenciadas por LLMs. Se propone que el framework permita de manera preliminar abstraer y reducir complejidad de algunos de estos aspectos listados a continuación:

- Creación de prompts.
- Selección de estrategias de aumentación de prompts.
- Incorporación de información de dominio externos del framework mediante la incorporación de bases de datos y/o Knowledge graphs.

El desarrollo del Framework es potencialmente aplicable en diversos dominios, las pruebas preliminarmente se enfocarán en la selección de un dominio particular (educación, salud, industria y gastronomía).

Resultados y Objetivos

Los resultados obtenidos contribuyen con el objetivos de obtener un motor que permita aumentar el prompt de un usuario, con el desarrollo de un framework; el motor recibirá como entrada el prompt del usuario y el del sistema, selecciona la aumentación del prompt y agrega información de dominio en forma de documentos / grafos de conocimiento que son externos al framework. como se indica en la figura 1.



Figura 1 Esquema conceptual Framework para la aumentación de prompts para modelos generativos de IA.

El objetivo del motor es aumentar el prompt. Para ello, se realizan un conjunto de transformaciones. En la figura 2 se puede observar la secuencia de pasos (En inglés Pipeline) que se busca aplicar al prompt del usuario. En el paso 1 , se busca determinar el dominio de la tarea que quiere realizar el usuario. Una vez detectado, se procede al paso 2 Selección de estrategia de aumentación en el que el motor decide qué estrategia de aumentación utilizar. En el paso 3, se creará un contexto para poder agregar información adicional que no está presente en el texto del prompt a partir de fuentes externas de datos. Por último, en el paso 4 se alimenta el prompt aumentado al LLM elegido (LLama2, Gemma o GPT).

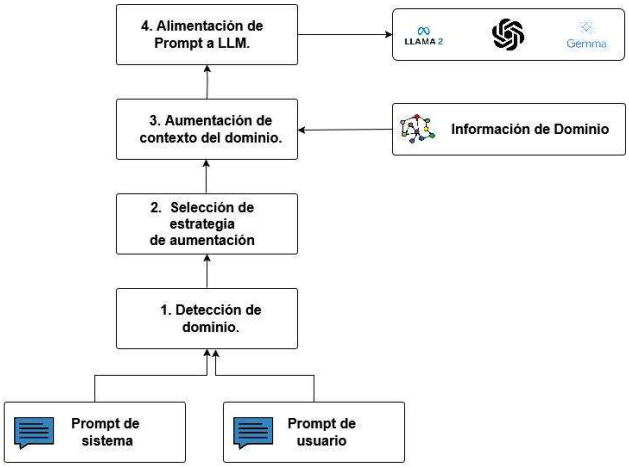


Figura 2 Esquema conceptual del pipeline que realiza el motor de aumentación de prompts.

De esta manera, se busca que el usuario obtenga los resultados deseados mediante la secuencia de transformaciones mencionadas. Un detalle a destacar es que se busca que el framework sea independiente del modelo generativo utilizado, ofreciendo la posibilidad de integrar cualquier modelo generativo (LLama2, GPT o Gemma).

Formación de Recursos Humanos

El grupo de investigación está conformado por tres investigadores formados y un investigador en formación, trabajando en el área de IA.

Referencias

[1] GPT-4 Technical Report. Disponible en https://arxiv.org/abs/2303.08774. Accedido el 5/2/2024

[2] OpenIA, ChatGPT. Disponible en https://openai.com/blog/chatgpt. Accedido el 12/2/2025.

[3] Facebook, LLama 2. Disponible en https://llama.meta.com/. Accedido el 12/2/2025.

[4] Google, Gemini. Disponible en https://deepmind.google/technologies/gemini/#introduction. Accedido el 12/2/2025.

[5] Liang, W., et al. (2024). DeepSeek-V3 Technical Report. Disponible en https://arxiv.org/abs/2412.19437. Accedido el 12/2/2025.

[6] Liang, W., et al. (2025). DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning . Disponible en https://arxiv.org/abs/2501.12948 . Accedido el 12/2/2025.

[7] Hugging Face Team. (2024). Open-R1: A fully open reproduction of DeepSeek-R1. Disponible en https://huggingface.co/blog/open-r1 Accedido el 12/2/2025.

[8] Wikipedia, Hallucination. Disponible en https://en.wikipedia.org/wiki/Hallucination_(artificial_intelligence). Accedido el 5/2/2024.
Open IA, Prompt engineering. Disponible en https://platform.openai.com/docs/guides/prompt-engineering. Accedido el 12/2/2025.

[9] IBM. (2024). Prompt engineering. Disponible en https://www.ibm.com/es-es/think/topics/prompt-engineering. Accedido el 12/2/2025.