


Universidad Politécnica
de Madrid

**Escuela Técnica Superior de Ingenieros Informáticos**




Máster Universitario en Inteligencia Artificial

Trabajo Fin de Máster

# Sistema de Búsqueda Inteligente aplicando Retrieval-Augmented Generation (RAG)


Autor: Adrián Hernández Suárez
Tutor: Óscar Corcho García



Madrid, Julio 2024

Este Trabajo Fin de Máster se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

*Trabajo Fin de Máster*
*Máster Universitario en* Inteligencia Artificial

*Título:* Sistema de Búsqueda Inteligente aplicando Retrieval-Augmented Generation (RAG)

Julio 2024

*Autor:* Adrián Hernández Suárez
*Tutor:* Óscar Corcho García
Artificial Intelligence
ETSI Informáticos
Universidad Politécnica de Madrid

# Resumen

El Trabajo Fin de Máster presentado se centra en el desarrollo de un sistema de búsqueda semántica utilizando la metodología de Generación Aumentada por Recuperación (Retrieval-Augmented Generation, RAG) para los documentos del Boletín Oficial de la Universidad de La Laguna (BOULL). El objetivo principal es mejorar la precisión y relevancia de la información recuperada, facilitando así el acceso a la información por parte de los usuarios.

Para lograr este objetivo, se ha implementado un pipeline de procesamiento de datos que incluye la segmentación de documentos en chunks de contexto, la generación de representaciones vectoriales mediante modelos de lenguaje preentrenados y el almacenamiento de estas representaciones en una base de datos vectorial, ChromaDB. El sistema de recuperación de información utiliza técnicas avanzadas de cálculo de distancias para identificar los fragmentos de texto más relevantes, los cuales son posteriormente utilizados como contexto por un modelo de IA Generativa para generar respuestas precisas y coherentes a las consultas de los usuarios.

La evaluación del sistema se ha llevado a cabo mediante un conjunto de preguntas diseñadas para probar tanto la calidad de la recuperación de información como la capacidad del modelo generativo para proporcionar respuestas útiles. Los resultados obtenidos demuestran que el enfoque propuesto mejora significativamente la precisión y relevancia de la información recuperada, destacando la efectividad de la metodología RAG en este contexto.

Este trabajo no solo aporta una solución técnica al problema de recuperación de información en documentos oficiales, sino que también proporciona una base sólida para futuras investigaciones y desarrollos en el campo del procesamiento del lenguaje natural aplicado a la gestión de información en administraciones públicas.

# Abstract

The presented Master's Thesis focuses on the development of a semantic search system utilizing the Retrieval-Augmented Generation (RAG) methodology for the documents of the Official Bulletin of the University of La Laguna (BOULL). The primary objective is to improve the precision and relevance of the retrieved information, thereby facilitating access to information for users.

To achieve this goal, a data processing pipeline has been implemented, including the segmentation of documents into contextual chunks, the generation of vector representations using pre-trained language models, and the storage of these representations in a vector database, ChromaDB. The information retrieval system employs advanced distance calculation techniques to identify the most relevant text fragments, which are then used as context by a Generative AI model to produce accurate and coherent responses to user queries.

The system evaluation was conducted using a set of questions designed to test both the quality of information retrieval and the generative model's ability to provide useful responses. The results demonstrate that the proposed approach significantly improves the precision and relevance of the retrieved information, highlighting the effectiveness of the RAG methodology in this context.

This work not only offers a technical solution to the problem of information retrieval in official documents but also provides a solid foundation for future research and developments in the field of natural language processing applied to information management in public administrations.

# Tabla de contenidos


**1. Introducción** **1**
1.1. Antecedentes . . . 1
1.2. Motivación . . . 2
1.3. Problemática . . . 2
1.4. Alcance del proyecto . . . 3

**2. Estado del arte** **5**
2.1. Búsqueda Semántica . . . 5
2.1.1. Mejoras recientes en la búsqueda semántica . . . 6
2.1.1.1. Modelos contextuales . . . 7
2.2. Inteligencia Artificial Generativa . . . 8
2.2.1. Mejoras recientes en la IA Generativa . . . 9
2.3. Retrieval-Augmented Generation (RAG) . . . 9
2.4. Bases de datos vectoriales . . . 10

**3. Diseño de la solución** **13**
3.1. Estructura de la solución . . . 13
3.1.1. Tecnologías . . . 14
3.1.2. Descripción de los datos . . . 15
3.2. Preparación del conjunto de datos . . . 16
3.2.1. Análisis de los datos . . . 16
3.2.2. Segmentación del conjunto de datos (Chunks) . . . 18
3.2.2.1. Nivel I: Título y Resumen . . . 18
3.2.2.2. Nivel II: Documento completo . . . 19
3.2.2.3. Nivel III: Segmentación por página . . . 19
3.2.2.4. Nivel IV: Segmentación por párrafo . . . 20
3.2.3. Pre-procesado de los datos . . . 22
3.2.4. Extracción de embeddings . . . 22
3.2.4.1. Almacenamiento de embeddings (VecDBs) . . . 23
3.3. Sistema de Recuperación de Información . . . 24
3.3.1. Selección de la medida de cálculo de distancia . . . 24
3.3.2. Optimización de la selección de chunks . . . 25
3.4. Sistema de Generación de Respuesta . . . 26
3.4.1. Importancia del Desarrollo de un Prompt de Calidad . . . 26

**4. Evaluación de los resultados** **29**
4.1. Sistema de Recuperación de Información . . . 31
4.1.1. Métricas de evaluación . . . 31

4.1.1.1. EM: Exact Match . . . . . 31
4.1.1.2. F-1 Score . . . . . 31
4.1.1.3. F-N Score . . . . . 32
4.1.1.4. fBERT . . . . . 32
4.1.1.5. SAS: Semantic Answer Similarity . . . . . 32
4.1.2. Evaluación independiente de los modelos . . . . . 33
4.1.2.1. Modelo: Multi-qa-MiniLM-L6-cos-v1 . . . . . 33
4.1.2.2. Modelo: Multilingual E5 . . . . . 34
4.1.2.3. Modelo: BG3 M3-Embedding . . . . . 35
4.1.2.4. Modelo: Siamese BERT . . . . . 36
4.1.2.5. Modelo: LABSE . . . . . 37
4.1.2.6. Modelo: Paraphrase-multi-MiniLM-L12-v2 . . . . . 38
4.1.2.7. Modelo: Distiluse-base-multi-cased-v2 . . . . . 39
4.1.2.8. Modelo: DistilRoBERTa . . . . . 40
4.1.3. Comparativa de modelos . . . . . 41
4.2. Sistema de Generación de Respuesta . . . . . 42
4.2.1. Métricas de evaluación . . . . . 42
4.2.1.1. CP: Context Precision . . . . . 42
4.2.1.2. FF: Faithfulness . . . . . 42
4.2.1.3. AR: Answer Relevancy . . . . . 42
4.2.1.4. CR: Context Recall . . . . . 43
4.2.2. Evaluación de los modelos . . . . . 43
4.3. Ejemplos End-to-End . . . . . 46

**5. Conclusiones y líneas futuras** **49**
5.1. Conclusiones . . . . . 49
5.2. Líneas futuras . . . . . 50

**Bibliografía** **51**

# Índice de figuras

1.1. Problemática del proyecto . . . . . 2

2.1. Funcionamiento básico Búsqueda Semántica . . . . . 5
2.2. Esquema Word2Vec - CBOW . . . . . 6
2.3. Esquema Arquitectura Transformer . . . . . 7
2.4. Esquema Red Neuronal LSTM . . . . . 8
2.5. Esquema arquitectura RAG . . . . . 10
2.6. Estructura de una base de datos vectorial . . . . . 11

3.1. Estructura General de la Solución . . . . . 13
3.2. Sede Electrónica de la Universidad de La Laguna . . . . . 15
3.3. Pipeline I - Preparación del conjunto de datos . . . . . 16
3.4. Cantidad de documentos por tipo de etiqueta . . . . . 17
3.5. Histograma de la frecuencia de palabras por tipo de documento . . . . . 17
3.6. Ejemplo de conversión PDF/A a lenguaje tipado HTML . . . . . 20
3.7. Técnica de overlap en segmentación de párrafos . . . . . 21
3.8. Similitud semántica en base de datos vectorial - ChromaDB . . . . . 24
3.9. Concepto del sistema de generación de respuesta . . . . . 26

# Índice de Tablas

4.1. Resultados de las métricas para el modelo Multi-qa-MiniLM-L6-cos-v1 . 33
4.2. Resultados de las métricas para el modelo Multilingual E5 . . . . . 34
4.3. Resultados de las métricas para el modelo BG3 M3-Embedding . . . . . 35
4.4. Resultados de las métricas para el modelo Siamese Bert . . . . . 36
4.5. Resultados de las métricas para el modelo LABSE . . . . . 37
4.6. Resultados de las métricas para el modelo Paraphrase-multi-MiniLM-L12-v2 . . . . . 38
4.7. Resultados de las métricas para el modelo Distiluse-base-multi-cased-v2 39
4.8. Resultados de las métricas para el modelo DistilRoBERTa . . . . . 40
4.9. Comparativa precisión de los modelos . . . . . 41
4.10. Comparativa modelos generativa con Multi-qa-MiniLM-L6-cos-v1 . . . . 43
4.11. Comparativa modelos generativa con Multilingual E5 . . . . . 43
4.12. Comparativa modelos generativa con BG3 M3-Embedding . . . . . 43
4.13. Comparativa modelos generativa con Siamese BERT . . . . . 44
4.14. Comparativa modelos generativa con LABSE . . . . . 44
4.15. Comparativa modelos generativa con Paraphrase-multi-MiniLM-L12-v2 44
4.16. Comparativa modelos generativa con Distiluse-base-multi-cased-v2 . . . 44
4.17. Comparativa modelos generativa con DistilRoBERTa . . . . . 45

# Capítulo 1

# Introducción

En este apartado se introduce el problema planteado por la Universidad de La Laguna con el fin de estudiar la viabilidad de implementar un sistema de búsqueda inteligente para facilitar el acceso a la información del Boletín Oficial de la Universidad de La Laguna (BOULL, Gobierno (2024)) por parte de los usuarios. El objetivo es proporcionar una visión general de los aspectos clave del problema, su complejidad y alcance, con el fin de contextualizar el trabajo de investigación realizado en este Trabajo Fin de Máster.

## 1.1. Antecedentes

En los últimos años los motores de búsqueda, Brin et al. (1998), han avanzado significativamente, desde los sistemas basados en palabras clave, hasta modelos de lenguaje, H. Wang et al. (2023), que comprenden el contexto y la semántica del texto. Con las mejoras en el campo del Procesamiento del Lenguaje Natural (NLP, por sus siglas en inglés) M. A. Tahir et al. (2023), surgieron sistemas de búsqueda basados en representaciones vectoriales del texto, denominados embeddings E. Almarwani et al. (2019), permitiendo una comprensión más profunda de las relaciones semánticas, mejorando la recuperación de información.

Paralelamente, los modelos de IA Generativa  et al. (2023), han recorrido un camino similar a los motores de búsqueda. Con el desarrollo de las redes neuronales, Schmidhuber (2014), y la creación de modelos secuenciales como las Redes Neuronales Recurrentes (RNNs, por sus siglas en inglés) Sherstinsky (2019) o las más avanzadas LSTMs Hochreiter et al. (1997), estos modelos pasaron de basarse en reglas gramaticales básicas para generar texto a manejar secuencias de datos más complejos. Sin embargo, el verdadero punto de inflexión para ambos sistemas fue la introducción de la arquitectura basada en Transformers, Vaswani (2017). La capacidad de procesar secuencias de texto en paralelo y capturar relaciones contextuales de largo alcance gracias al mecanismo de atención hace que supere las limitaciones presentadas por los modelos secuenciales tradicionales anteriormente nombrados.

## 1.2. Motivación

La capacidad para acceder y recuperar datos relevantes de manera rápida y precisa es esencial, especialmente en instituciones como la Universidad de La Laguna. La gran cantidad de documentos oficiales, normativas y resoluciones, puede llegar a abrumar la tarea para recuperar información ya que los sistemas de búsqueda tradicionales a menudo no logran proporcionar resultados precisos debido a la falta de comprensión semántica y contextual.

Es por esto, que este proyecto se motiva por la necesidad de implementar un sistema avanzado de búsqueda semántica para los documentos del Boletín Oficial de la Universidad de La Laguna, donde el objetivo principal es facilitar al usuario el acceso a información de una manera rápida, precisa y coherente.

## 1.3. Problemática

Las administraciones públicas y las instituciones académicas, como la Universidad de La Laguna, cada vez más se enfrentan a desafíos en la gestión y recuperación de información. El Boletín Oficial de la Universidad de La Laguna (BOULL) contiene una gran cantidad de documentos oficiales abarcando normativas, resoluciones, planes de estudio, acuerdos y demás comunicados importantes. No obstante, en algunos casos la búsqueda y recuperación de información relevante dentro de estos documentos se puede convertir en un problema que dificulte la experiencia de los usuarios, desde el profesorado a los estudiantes. En la Figura 1.1 podemos apreciar los factores principales que dificultan la recuperación de información, la necesidad que eso genera y la posible solución del problema.

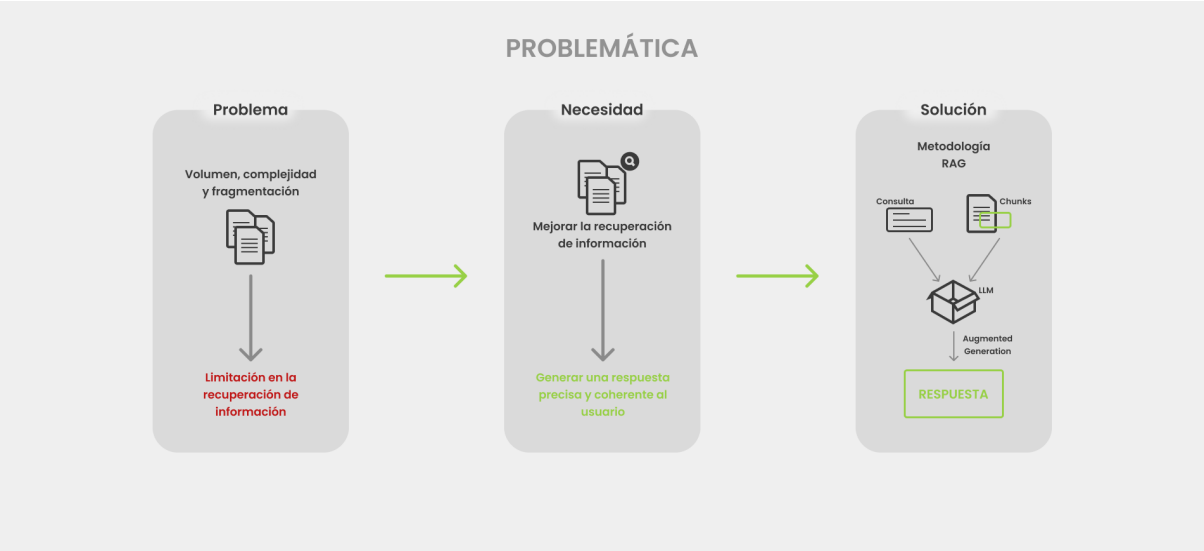



Figura 1.1: Problemática del proyecto

EL BOULL cuenta con una gran cantidad de documentos que se actualizan continuamente. Además, están redactados con un lenguaje técnico y formal, por lo que puede dificultar la búsqueda por palabras clave, posicionando al usuario en una costosa tarea de filtrado de documentos para encontrar la información que necesita. Por otro lado, la búsqueda por palabras clave limita los métodos de búsqueda debido a que

no se considera el contexto ni la semántica del texto, lo que genera una recuperación de información errónea e irrelevante. Tanto los estudiantes como el profesorado o el personal administrativo de la universidad necesitan acceder de una forma eficaz a información precisa para tomar ciertas decisiones o cumplir procedimientos administrativos, como puede ser la solicitud de una beca, y el no tener un sistema de búsqueda avanzado puede afectar a la eficiencia operativa de la universidad.

## 1.4. Alcance del proyecto

Teniendo en cuenta la problemática del proyecto, tenemos como objetivo la investigación, implementación y evaluación de un sistema de búsqueda inteligente para la recuperación de información de manera precisa y coherente.

Para ello, se hará uso de los documentos vigentes del Boletín Oficial de la Universidad de La Laguna (BOULL) y se aplicará la metodología de enfoque híbrido RAG (Retrieval-Augmented Generation), Lewis (2020), la cual combina métodos de recuperación y generación de texto aplicando técnicas y modelos de NLP (Natural Language Processing) con el objetivo de dar una respuesta precisa y coherente al usuario. Partiendo de esta base, tendremos 3 líneas diferentes de desarrollo: extracción y preparación de los datos, recuperación de información y generación de información precisa.

Queda fuera del alcance del proyecto:

- La implementación end-to-end de la solución como un producto o servicio.
- El desarrollo de un ChatBot o una API como potencial prototipo de la solución.
- La evaluación de modelos OpenSource en la Generación de la respuesta.

# Capítulo 2

# Estado del arte

## 2.1. Búsqueda Semántica

Históricamente los motores de búsqueda se basaban en el match literal de palabras, es decir, el objetivo era mostrar al usuario un ranking de los documentos que contienen más palabras clave dando por hecho que estos serían los que mejor respondería la consulta del usuario. Sin embargo, a lo largo del tiempo nos hemos dado cuenta que esta forma de búsqueda es un tanto ineficiente, ya que si no conoces las palabras clave de tu consulta no podrás obtener unos resultados óptimos o satisfactorios.

Para lidiar con esto se desarrolló el concepto de búsqueda semántica, Latard (2017). La Búsqueda Semántica es una técnica de Procesamiento del Lenguaje Natural (NLP, por sus siglas en inglés) la cual tiene como objetivo mejorar la relevancia y precisión de los resultados de búsqueda. Lo que se busca a través de la semántica es conocer el significado o el contexto de una frase o palabra y a través de este contexto, encontrar relaciones dentro de los documentos. Si pudiéramos hacer un símil, la búsqueda semántica sería como buscar un libro por su historia en vez de por el título.

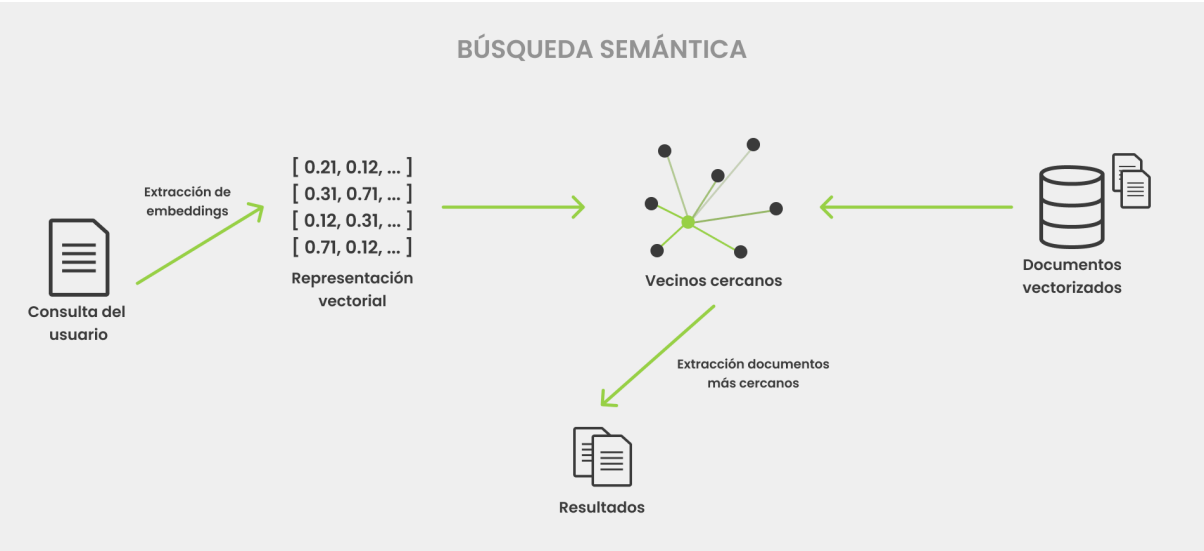



Figura 2.1: Funcionamiento básico Búsqueda Semántica

Este cambio en los motores de búsqueda y/o en la forma de recuperar información ha presentado mejoras significativas en comparación con la búsqueda basada en palabras clave. La comprensión del contexto, la intención del usuario o incluso el poder diferenciar entre diferentes significados de una palabra dependiendo del contexto de la frase hace que la búsqueda semántica muestre resultados más precisos y con más conocimiento, convirtiéndola en una herramienta sumamente útil para consultas complejas como puede ser la búsqueda de información en artículos científicos, documentación legal o incluso información médica.

### 2.1.1. Mejoras recientes en la búsqueda semántica

Las técnicas de búsqueda semántica se basan en una variedad de algoritmos y modelos de NLP, al principio se trabajaba con modelos de lenguaje como Word2Vec Mikolov (2013), GloVe Jeffrey Pennington (2014) o Fastext Bojanowski (2017), los cuales representan palabras en un espacio vectorial donde las palabras con contextos similares se encuentran más cerca unas de otras, permitiendo que el sistema entienda relaciones semánticas más profundas. Word2Vec ha sido la base en el avance de la búsqueda semántica al permitir que, a través de representaciones vectoriales usando redes neuronales, los sistemas puedan comprender las similitudes semánticas entre palabras.

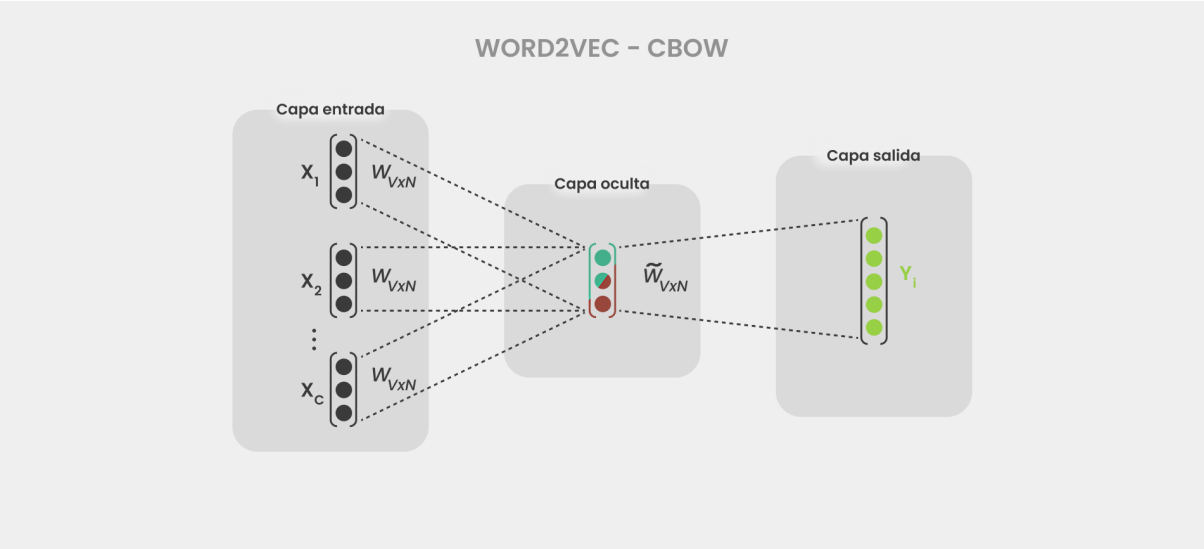



Figura 2.2: Esquema Word2Vec - CBOW

Sin embargo, estos modelos presentan una serie de limitaciones clave, como el desconocimiento del contexto. Los embeddings generados por los modelos de lenguaje como Word2Vec son estáticos, es decir, independientemente del contexto de la frase, una palabra siempre está representada por el mismo vector. Esto es problemático para palabras polisémicas que tienen diferentes significados según el contexto en el que se utilicen. Debido a esto, surge la necesidad de crear una solución que modele este comportamiento.

#### 2.1.1.1. Modelos contextuales

Los modelos contextuales Peters (2018), son una mejora de los modelos de lenguaje anteriormente comentados, tienen la capacidad de generar representaciones dinámicas de las palabras en función de su contexto dentro de una frase. Para superar las limitaciones de sus predecesores, los modelos contextuales generan embeddings que capturan el significado de una palabra en relación con las palabras que la rodean. Para conseguir esto se introdujo una nueva arquitectura, los Transformers.

La arquitectura Transformer es la base de muchos modelos contextuales, gracias al mecanismo de self-attention, se puede evaluar la importancia de cada palabra en una frase con respecto al resto de palabras, capturando asi las relaciones entre cada una de ellas. Además, esta arquitectura puede capturar contextos de largo alcance, por lo que supera las limitaciones de los modelos secuenciales tradicionales como las LSTM.

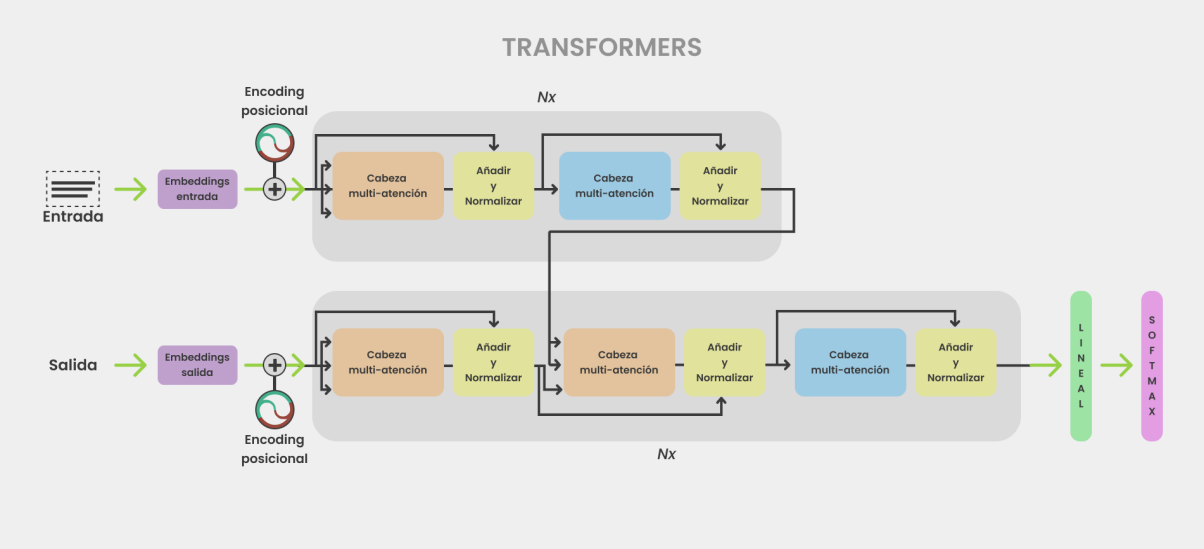



Figura 2.3: Esquema Arquitectura Transformer

Dentro de la arquitectura Transformer podemos identificar modelos clave como BERT Devlin (2019), el cual tiene un gran desempeño en la tarea de búsqueda semántica. BERT es un modelo de lenguaje pre-entrenado Qiu (2020) que utiliza la arquitectura Transformer para procesar texto de manera bidireccional, es decir, se considera tanto la parte izquierda como la derecha de una palabra simultáneamente. Esta capacidad de entender el contexto bidireccional lo convierte en un modelo muy útil para tareas que requieren una comprensión profunda del lenguaje. Dentro de los modelos basados en Encoders podemos destacar los modelos BGE Chen (2024) y ME5 Wang (2024) los cuales han dado buenos resultados en el proyecto y están teniendo una alta repercusión en la tarea de Búsqueda Semántica.

- El modelo BGE se basa en la arquitectura de BERT, es decir, procesa las secuencias de texto en ambas direcciones permitiendo que el modelo entienda el contexto completo. Ha sido entrenado con grandes corpus de datos y las aplicaciones son muy parecidas a las de BERT añadiendo capacidades generativas, permitiendo así no solo entender el texto sino también generarlo de forma coherente.

- El modelo ME5 también se basa en la arquitectura de Encoders pero no directamente de BERT, sino de variantes como mBERT, Telmo Pires (2019) o RoBERTa, **Liu2019**. Esto es porque ME5 está entrenado con datos en diversos idiomas, permitiendo que el modelo capture de forma efectiva contextos lingüísticos diversos. Aunque ME5 sea un modelo entrenado para dar un buen desempeño multilenguaje, su pre-entreno con grandes corpus de datos abarcando una amplia variedad de idiomas, hace que sus resultados sean sumamente prometedores.

## 2.2. Inteligencia Artificial Generativa

La Inteligencia Artificial Generativa (GenAI por sus siglas en inglés) hace referencia a un conjunto de métodos diseñados para generar contenido nuevo y original a partir de unos datos iniciales. Dentro del campo del Procesamiento del Lenguaje Natural estos modelos tienen la capacidad de generar texto coherente y contextualmente relevante, abriendo una gran gama de aplicaciones como la traducción automática, los chatbots o los asistentes virtuales populares como Siri o Alexa. Históricamente se utilizaban reglas gramaticales y reglas formales para establecer una forma de producir lenguaje natural, pero estas técnicas eran tan limitadas que era casi imposible crear un contenido muy complejo. Para acabar con esta limitación, y gracias al desarrollo de las Redes Neuronales Artificiales, la capacidad de la IA Generativa empezó a aumentar drásticamente. Sin embargo, los primeros modelos de Redes Neuronales como las RNNs tenían serios problemas con el desvanecimiento del gradiente, es decir, no conseguían manejar secuencias de datos muy largas. Gracias al posterior desarrollo de las LSTM y las GRU (Gated Recurrent Units, Cho (2014)) se logró aumentar dichas secuencias y por ende mejorar la generación de texto.

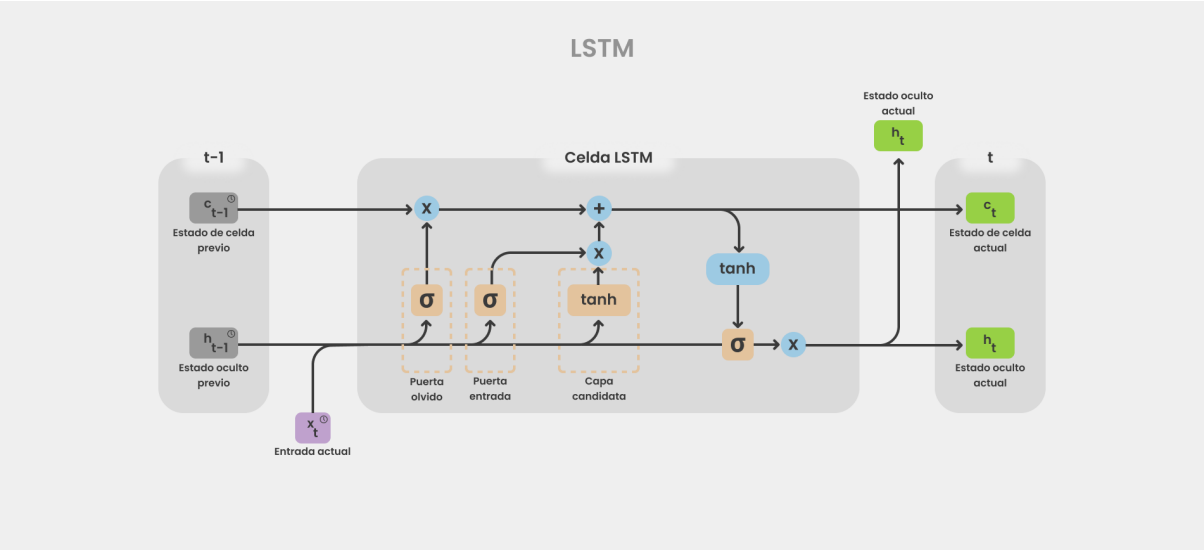



Figura 2.4: Esquema Red Neuronal LSTM

Posterior a las redes LSTM se desarrollaron las Redes Neuronales GANs (Generative Adversarial Networks, Goodfellow (2014)) las cuales consisten en dos redes neuronales que compiten entre sí, una creada para generar imágenes o texto y otra que se utiliza de discriminador. La idea de esto es que el discriminador intente distinguir

entre los datos generados por la otra red neuronal y los datos reales.

### 2.2.1. Mejoras recientes en la IA Generativa

Las mejoras recientes en la IA Generativa han sido impulsadas por la introducción de la arquitectura Transformer, este cambio de paradigma marcó un antes y un después en la evolución de la IA Generativa. Gracias al mecanismo de self-attention comentado en el apartado anterior, es posible procesar secuencias de texto en paralelo y capturar relaciones contextuales de largo alcance de manera eficiente, superando así las limitaciones de los modelos secuenciales tradicionales. Dentro de esta misma estructura Transformer podemos destacar un modelo clave en la tarea de generación de texto, GPT (Generative Pre-trained Transformer, Radford (2018)).

GPT es una arquitectura de IA Generativa que ha marcado un antes y un después dentro del mundo del Procesamiento del Lenguaje Natural. Este modelo es capaz de generar texto altamente coherente a partir de breves indicaciones textuales, denominadas prompt. Utilizando la arquitectura Transformer, el modelo es capaz de aprender patrones y contextos a partir de grandes corpus de texto, lo que le permite comprender y producir lenguaje natural de manera avanzada. Dentro de la familia GPT contamos con varias versiones cada una de ellas con más cantidad de parámetros, la más reciente es GPT-4o OpenAI (2023) la cual ha mejorado significativamente la calidad y coherencia del texto generado aumentando de forma considerable el desempeño en tareas como traducción automática, asistencia virtual o chatbots.

Por otro lado, actualmente se han desarrollado modelos multi-modales los cuales integran múltiples tipos de datos para la realización de tareas complejas. Estos modelos son capaces de aprender representaciones conjuntas de diferentes modalidades, permitiendo una mejor interpretación y generación de contenido. En este caso destacan aplicaciones como las de generación de imágen a partir de prompt de texto, modelos como DALL-E, Ramesh (2021) de OpenAI OpenAI (2023) como GPT pueden generar imágenes completamente nuevas a partir de descripciones textuales detalladas. Dependiendo de la naturaleza de los datos y del objetivo del proyecto, los modelos multi-modales suponen una mejora con respecto a los modelos uni-modales ya que permiten una mayor comprensión, una mejor interacción y una mejor generación de contenido.

## 2.3. Retrieval-Augmented Generation (RAG)

En los últimos años hemos visto cómo dos de las técnicas más potentes del mundo de la Inteligencia Artificial han ido evolucionando y mejorando los sistemas de recuperación y generación de información. Sin embargo, ambos modelos presentan una serie de limitaciones las cuales entorpecen el desarrollo de ambas técnicas. Los modelos generativos, como GPT, aunque tienen la capacidad de generar texto con una gran relevancia y coherencia, a veces no son capaces de procesar información de nicho, es decir, carecen de información específica para ciertos campos. Estos modelos se entrenan con grandes corpus de datos, por lo que su conocimiento se limita a la información procesada durante dicho entrenamiento, esto quiere decir que si realizamos consultas fuera de los datos de entrenamiento, no va a ser capaz de generar información coherente. Además, si quisiéramos aumentar su base de conocimiento o adaptar el conocimiento del modelo al campo de estudio en concreto, tendríamos

que realizar un re-entrenamiento completo, lo cual es una tarea sumamente costosa y poco práctica. Por otro lado, los modelos de recuperación de información se basan en la búsqueda de documentos relevantes en relación a la consulta, su limitación es que no son capaces de sintetizar dicha información en una respuesta al usuario, por lo que es parte del mismo extraer la información relevante del fragmento de texto que extrae el modelo. A partir de estas dos limitaciones, se generó una motivación y se desarrolló RAG (Retrieval-Augmented Generation).

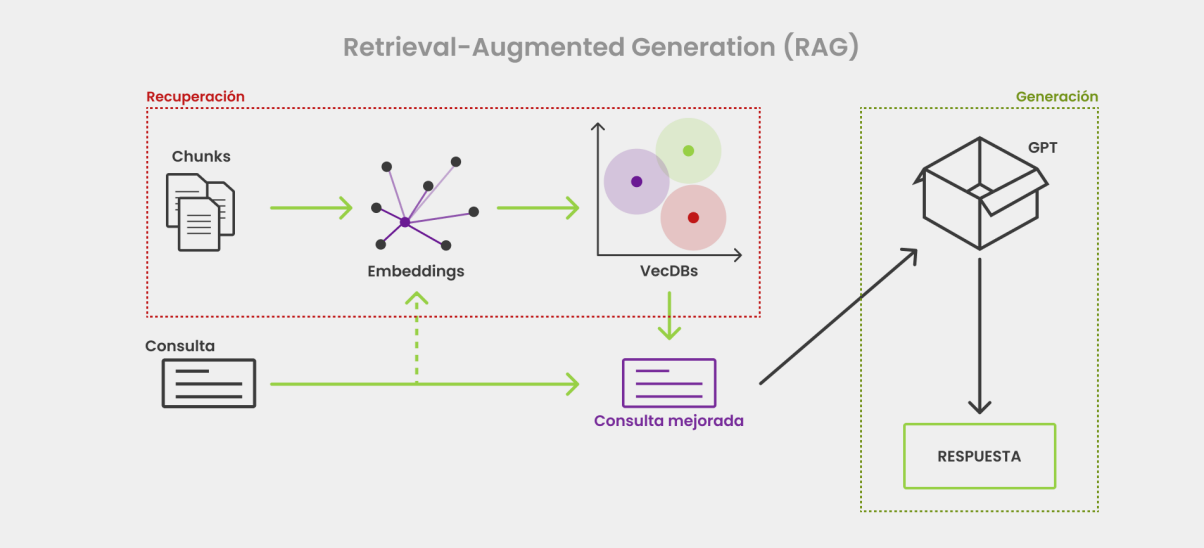



Figura 2.5: Esquema arquitectura RAG

La Generación Aumentada por Recuperación (RAG, por sus siglas en inglés) es una técnica que tiene como objetivo mejorar los LLMs (Large Language Models, Wang (2023)) integrando conocimiento de fuentes externas. RAG es una combinación de dos mundos, tiene la capacidad de los modelos de recuperación para encontrar información relevante y específica, y la capacidad de los modelos generativos de sintetizar y generar una respuesta coherente para la consulta del usuario. Gracias a este sistema, se tiene la posibilidad de acceder a conjuntos de datos actualizados en tiempo real, mejorando la precisión y aumentando el conocimiento que contienen las respuestas generadas. RAG surge como solución a las limitaciones comentadas anteriormente al aprovechar fuentes de conocimiento externas mejora la respuesta de los LLMs. Se ha convertido en un elemento crucial para mantener la precisión y la relevancia en aplicaciones como Chatbots asegurando que los usuarios obtengan las respuestas más fiables y exactas posibles.

## 2.4. Bases de datos vectoriales

La aparición de RAG y la evolución de las últimas tecnologías y metodologías de la Inteligencia Artificial dentro del campo de Procesamiento del Lenguaje Natural generaron una limitación en otros aspectos. Todo este conocimiento se tiene que almacenar de alguna forma para poder acceder a él sin la necesidad de aplicar en cada petición un proceso de vectorización, pero las bases de datos tradicionales no son capaces de manejar datos no estructurados. Las bases de datos relacionales, Codd (1970) y NoSQL tradicionales manejan correctamente y de forma eficiente los datos

estructurados o semi-estructurados, pero, no son capaces de manejar datos como texto, imágenes o incluso audio que requieren comparaciones basadas en similitud, es por ello que se crean las Bases de Datos Vectoriales (VecDBs, por su siglas en inglés).

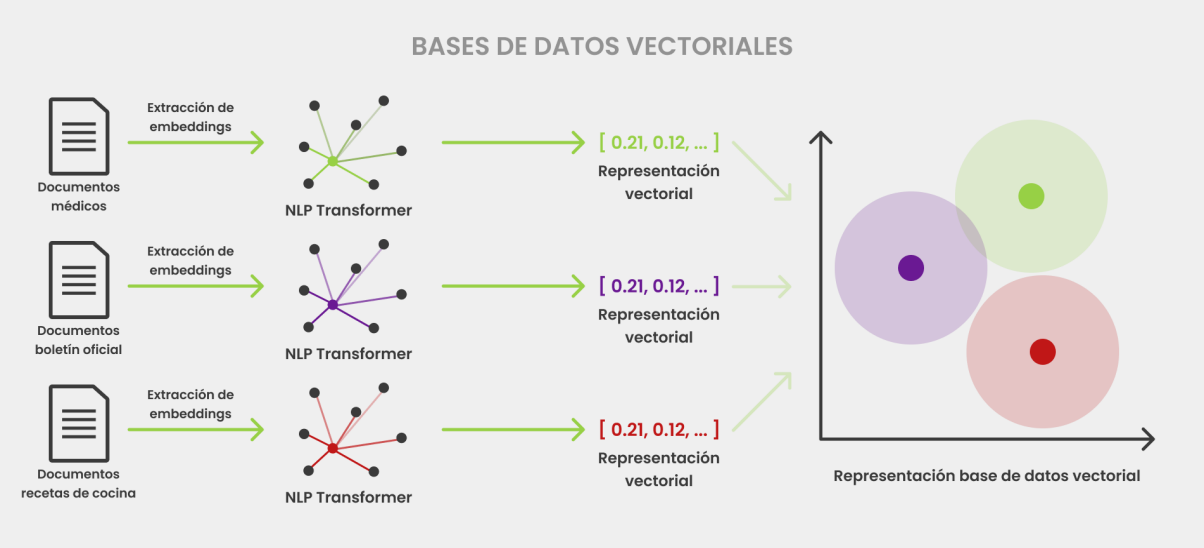



Figura 2.6: Estructura de una base de datos vectorial

Las bases de datos vectoriales, Wang (2023) están especializadas para almacenar, indexar y buscar vectores de alta dimensionalidad, es decir, la representación numérica de datos textuales, imágenes, etc. Estas bases de datos son cruciales en aplicaciones donde los datos se tengan que transformar en embeddings vectoriales, como puede ser la búsqueda semántica. Gracias a esto, conseguimos realizar búsquedas mucho más rápidas y precisas mejorando la relevancia de los resultados. En la Figura 2.6 podemos ver la implementación de una base de datos vectorial y sus componentes clave.

Actualmente existen diversas bases de datos vectoriales, incluso PostgreSQL Michael Stonebraker et al. (1986) está desarrollando una adaptación de la misma, pero, la que podríamos catalogar como estado del arte y que más se está utilizando en las implementaciones es ChromaDB, Team (2023). ChromaDB es una VecDBs open-source adaptada para facilitar la integración con LLMs teniendo una gran utilidad en contextos como la búsqueda semántica o sistemas de recomendación. En nuestro caso, ChromaDB nos permite realizar búsquedas en grandes volúmenes de datos textuales, recuperando documentos que son semánticamente similares a una consulta dada. Para conseguir esto, se utilizan medidas de similitud como la Distancia Coseno, la Distancia Euclídea o la Distancia Jaccard, las cuales, dependiendo de la naturaleza de los datos son un estándar en la búsqueda semántica. Además, ChromaDB ya está dando pasos en el uso de modelos basados en grafos (GNNs, Zhou (2020)) los cuales son una línea de investigación reciente.

# Capítulo 3

# Diseño de la solución

## 3.1. Estructura de la solución

Para analizar con detalle y entender la propuesta de la solución, tomaremos como referencia la Figura 3.1. Como podemos observar, la solución la podemos dividir en 3 fases fundamentales: La preparación del conjunto de datos, El sistema de Recuperación de Información y el Sistema de Generación de texto. La preparación del conjunto de datos es el apartado con mayor carga de trabajo manual, y uno de los pasos más importantes del proyecto. Obtener unos datos de calidad que puedan mantener y estructurar el conocimiento es una parte fundamental en cualquier solución de Inteligencia Artificial y un paso clave dentro de este proyecto. Por otro lado, el sistema de Recuperación de Información y el de Generación de texto, han sido apartados más de investigación y documentación, donde el objetivo ha sido encontrar los modelos más prometedores, compararlos y evaluar sus resultados.

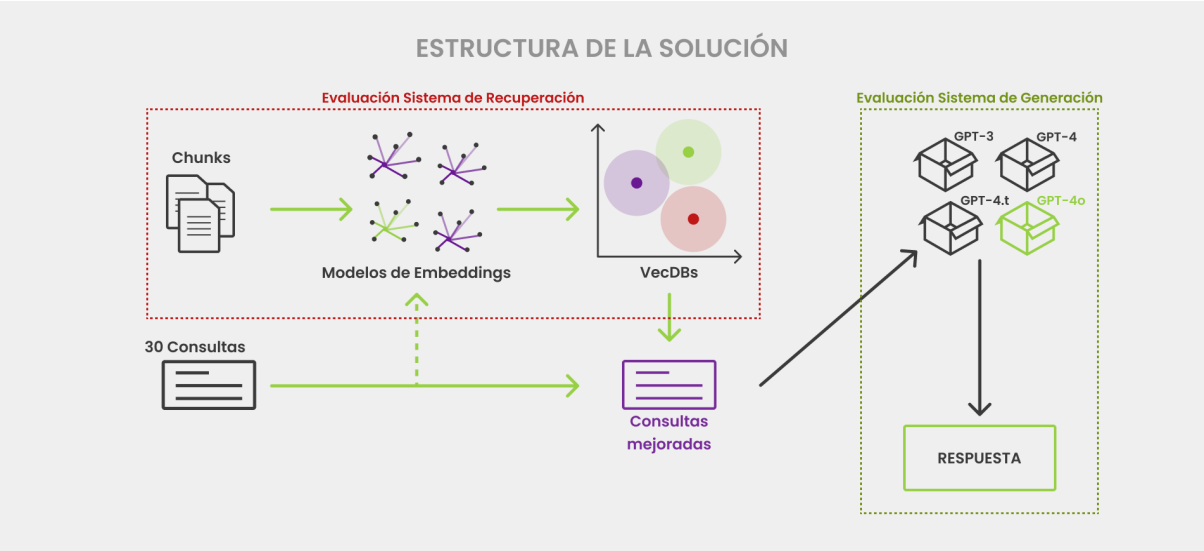



Figura 3.1: Estructura General de la Solución

### 3.1.1. Tecnologías

Para la realización del proyecto se ha optado por el lenguaje de programación Python, debido a que actualmente es el lenguaje de programación por excelencia para la resolución de problemas de este ámbito. Además, es un lenguaje con una alta versatilidad y una gran comunidad, lo cual facilita mucho la corrección de errores ocasionales y el descubrimiento de librerías que agilicen procesos pesados. Para ser más concretos, la preparación de los datos, la construcción y utilización de los modelos y la evaluación de cada una de las partes se ha realizado con las siguientes librerías:

- **Pandas**: Herramienta de análisis de datos y estructuras de datos en Python.
- **Numpy**: Librería fundamental para computación científica en Python, proporciona soporte para arrays y matrices multidimensionales.
- **Plotly**: Librería de gráficos interactivos para visualizar datos.
- **Hydra**: Framework para gestionar configuraciones complejas en aplicaciones Python.
- **Chromadb**: Base de datos de vectores para búsqueda de similitud y recuperación de información.
- **Preln**: Biblioteca para preprocesamiento y limpieza de datos de texto.
- **Torch**: Framework de aprendizaje profundo, también conocido como PyTorch.
- **Transformers**:Librería de modelos de transformadores preentrenados para NLP.
- **Mapply**: Librería para aplicar funciones de forma eficiente sobre pandas DataFrames utilizando multiprocessing.
- **Sentence_Transformers**: Librería para generar embeddings de texto utilizando modelos BERT y otros transformadores.
- **OpenAI**: API de OpenAI para acceder a modelos de inteligencia artificial avanzados como GPT.
- **Dataset**: Librería para trabajar con conjuntos de datos de forma eficiente y con soporte para múltiples formatos.
- **Ragas**: Librería para evaluación y análisis de sistemas de recomendación.
- **Llama_Parser**: Herramienta para analizar y extraer información de datos indexados con Llama.
- **PyMuPDF**: Librería para trabajar con archivos PDF, permite leer, escribir y modificar PDFs.

Entre otras librerías más secundarias que se utilizaron para poder realizar el proyecto de la forma más profesional, escalable y limpia posible. El código del proyecto tiene una estructura robusta, completa y modular, la cual engloba las diferentes fases del proyecto y las integra en un único directorio almacenado en una herramienta de control de versiones como GitHub, Zhou (2020).

### 3.1.2. Descripción de los datos

Para el desarrollo del proyecto se ha trabajada con dos conjuntos de datos diferentes. Un conjunto inicial con el historial de publicaciones en el Boletín Oficial de La Universidad de La Laguna (BOULL) con el cual podremos analizar más detalladamente la naturaleza de los datos y otro conjunto, con los documentos que actualmente se encuentran en vigor, los cuales usaremos para evaluar los resultados de la solución. En la Figura 3.2 podemos observar la Sede Electrónica de la universidad y las publicaciones de los diferentes documentos.

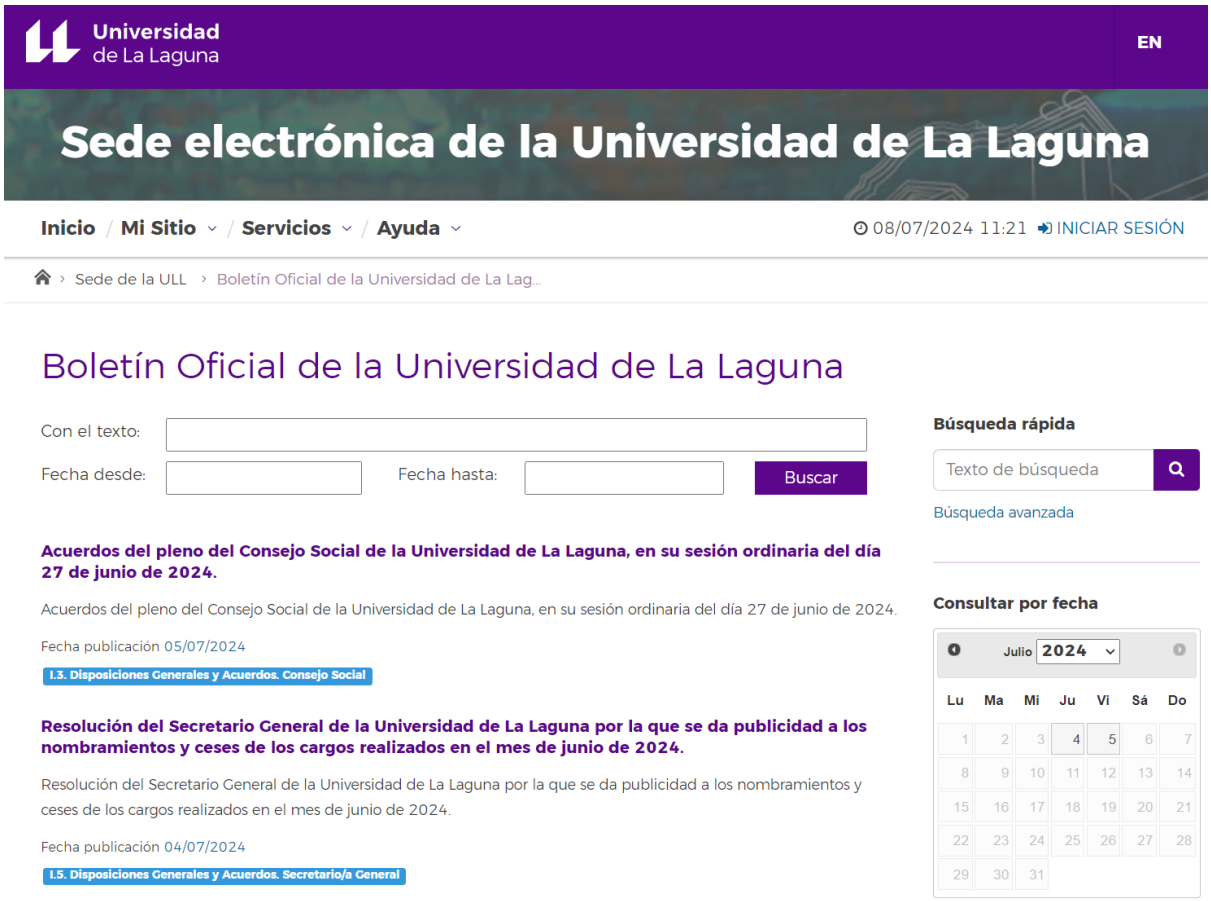



Figura 3.2: Sede Electrónica de la Universidad de La Laguna

El conjunto de datos más básico se ha extraído a través de un *Scrapping Web*, Chandrika (2020). Con esto, conseguimos generar un fichero CSV con el título del documento, el resumen, fecha de publicación, la etiqueta y la URL del documento completo. Esto lo usaremos para generar un pipeline base del proyecto, el cual tomaremos como referencia para el resto de implementaciones.

Los documentos no son todos PDF de tipo A, por lo que el tratamiento puede variar entre cada documento, además, no cuentan con una estructura fija, es decir, dependiendo del tipo de documento, la fecha de publicación o quién lo ha publicado, la estructura o incluso la tipografía puede variar.

## 3.2. Preparación del conjunto de datos

La preparación de los datos es una de las partes más importantes del proyecto. El objetivo principal es generar un conjunto de datos que capture y transmita la mayor cantidad de conocimiento posible. Además, es importante que tenga una buena segmentación, lo que implica que la división de los diferentes chunks de texto estén limpios pero sin perder contexto.

Como se mencionó en el apartado anterior, la extracción inicial se ha realizado mediante de una técnica de Scrapping. Con este proceso conseguimos generar un fichero con los datos complementarios de cada uno de los documentos. Paralelamente, se descargó cada fichero al completo y se almacenaron en un directorio del proyecto. Una vez realizada la extracción de los datos y apoyándonos en la Figura 3.3, generamos un pipeline de preparación del conjunto de datos, el cual tendremos como referencia a lo largo de los apartados siguientes.

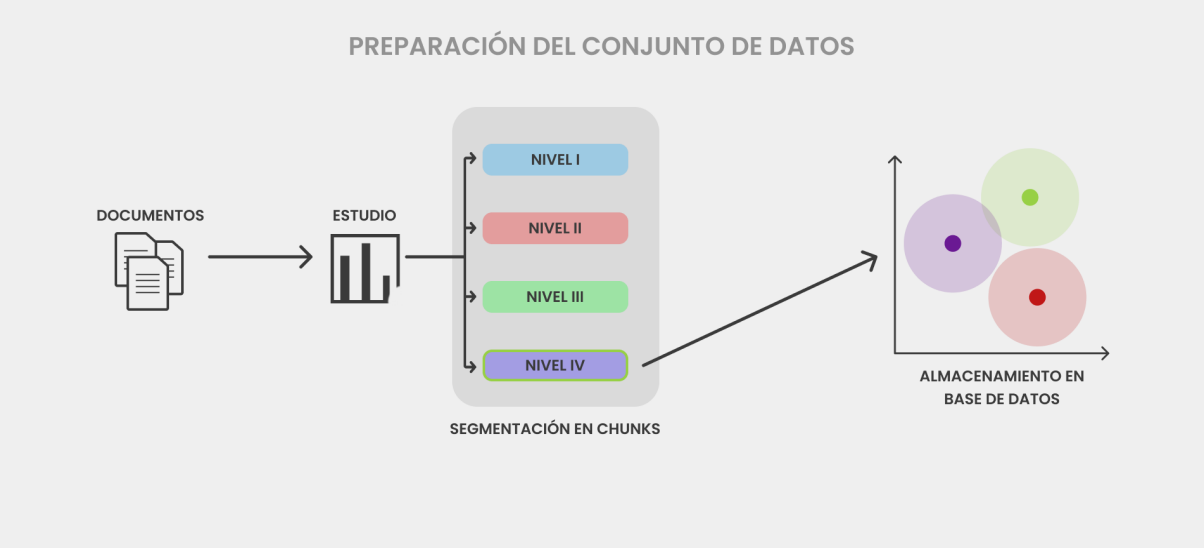



Figura 3.3: Pipeline I - Preparación del conjunto de datos

### 3.2.1. Análisis de los datos

Para el análisis de los datos, utilizaremos el conjunto de datos inicial que contiene el Título, Resumen, Fecha de publicación y la etiqueta de 1653 documentos. Estos documentos son históricos y, aunque no son adecuados para su uso directo en el sistema de Recuperación de Información, proporcionan una base sólida para analizar el contenido de los documentos. En la Figura 3.4 se puede observar que la etiqueta *Acuerdos y Disposiciones Generales* es dominante frente al resto de documentos. Sin embargo, también se identifican otras etiquetas relevantes como los Nombramientos o los ceses. Por otro lado, tenemos etiquetas menos frecuentes como los anuncios de convocatorias, los convenios, etc.

El objetivo principal de este proyecto no es simplemente clasificar los documentos y darle una respuesta al usuario, sino entender el contexto y el contenido de cada uno de ellos.

.En un proyecto de clasificación tradicional, el desbalanceo entre las diferentes ca-

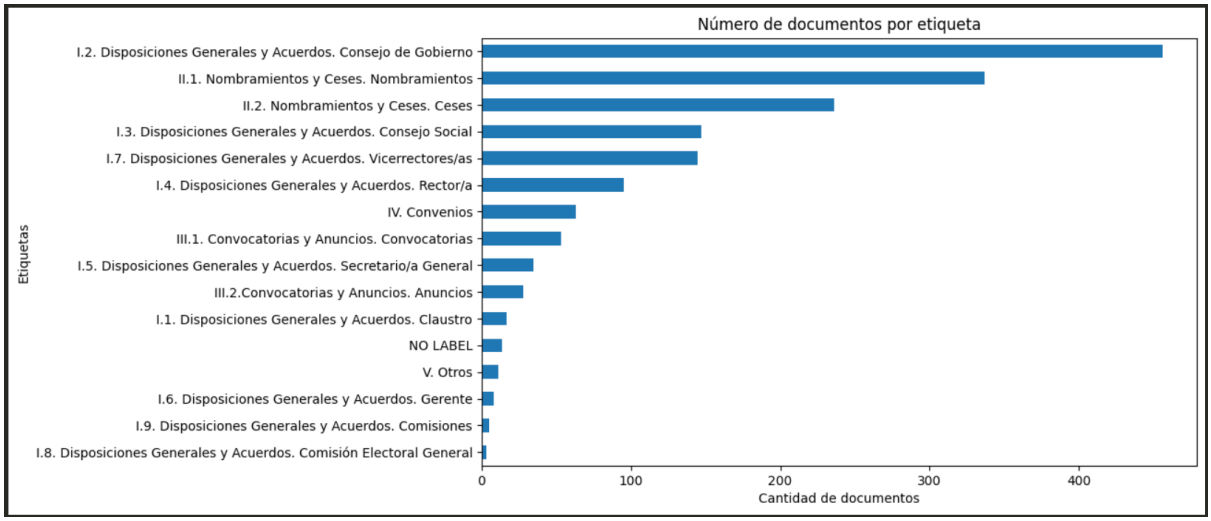



Figura 3.4: Cantidad de documentos por tipo de etiqueta

tegorías podría afectar negativamente el entrenamiento del modelo. Sin embargo, en nuestro caso, lo que buscamos es comprender las similitudes y diferencias entre los documentos para mejorar la precisión de la recuperación de información. Para conseguir esto, generamos un histograma de palabras clave (palabras con mayor frencuencia dentro de cada documento), en la Figura 3.5 vemos unos ejemplos para las etiquetas más relevantes.

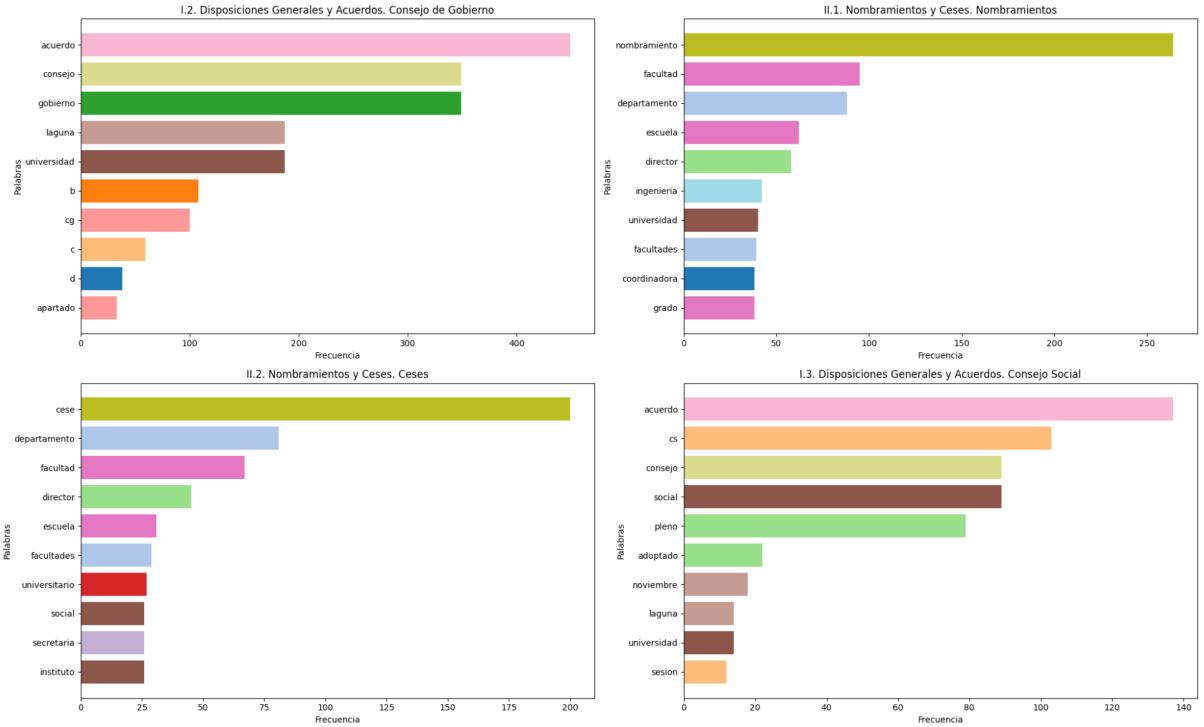



Figura 3.5: Histograma de la frecuencia de palabras por tipo de documento

Una característica interesante de estos histogramas es que, aunque los documentos puedan pertenecer a la misma categoría principal (p. ej, Disposiciones Generales y

Acuerdos), el contexto que se encuentra dentro de estos documentos puede variar significativamente. Esta variabilidad en el contexto es sumamente valiosa para el sistema de recuperación de información, ya que permite distinguir entre diferentes sub-temas y enfoques dentro de la misma categoría principal.

### 3.2.2. Segmentación del conjunto de datos (Chunks)

En el contexto del proyecto, la segmentación del conjunto de datos es un paso fundamental para mejorar la precisión y relevancia de los resultados obtenidos. La segmentación en chunks hace que los modelos de recuperación y generación funcionen de manera más eficiente y efectiva, ya que se centran en fragmentos de texto que son más específicos y contextualmente relevantes, mejorando así la calidad de las respuestas generadas.

La importancia de este procedimiento se divide en:

- **Mejorar la precisión de la recuperación de información**: Al realizar la división en chunks, es posible realizar búsquedas más precisas, donde los modelos sean capaces de identificar los fragmentos de texto que son directamente relevantes para una consulta específica.
- **Mantener un alto contexto y relevancia**: Gracias a esta segmentación, se puede mantener un mayor control del contexto dentro de cada chunk.

El proceso de segmentación que hemos diseñado, consta de 4 niveles de profundidad, de menor a mayor complejidad. Partimos de una línea base donde hacemos una primera iteración a grano grueso y vamos afinando hasta la segmentación por chunks de texto a nivel de párrafos contextuales.

#### 3.2.2.1. Nivel I: Título y Resumen

En esta sección, se trabajó con el objetivo de establecer una línea base sobre la cual se pudiera escalar y mejorar el algoritmo de segmentación. Utilizando el título y el resumen de los documentos, se construyó un algoritmo para la extracción de embeddings y se probaron diferentes medidas de distancias. Inicialmente, los resultados obtenidos con preguntas muy bien estructuradas y concisas no fueron del todo insatisfactorios. Sin embargo, cuando se utilizaron consultas más generales o abstractas, el modelo empezó a mostrar deficiencias en la recuperación de información.

Conclusiones del Nivel I:

- **Limitación en el contexto del resumen**: La cantidad de contexto en el resumen de los documentos es insuficiente para capturar toda la información relevante, lo que empeora la precisión del modelo.
- **Rendimiento aceptable en consultas bien estructuradas**: Si empleamos consultas poco sofisticadas y estructuralmente correctas, el modelo presenta unos resultados aceptables.
- **Mal rendimiento en consultas naturales**: En contraste, si empleamos lenguaje menos formal y la consulta no está estructurada correctamente, siendo incluso genérica, la capacidad de recuperación de información de calidad del modelo disminuye drásticamente.

#### 3.2.2.2. Nivel II: Documento completo

Para abordar las limitaciones observadas en el nivel anterior, se propuso utilizar el contexto completo del documento, es decir, que el sistema de recuperación de información detecte en que documento se encuentra la consulta del usuario. Sin embargo, este método puede presentar varias limitaciones. El uso del contexto completo implica manejar una ventana de contexto mucho más amplia, lo que provoca un coste computacional muy elevado. Además, en los modelos de generación de texto, la ventana de contexto disponible no es lo suficientemente grande como para contener el contexto de un documento completo. Esto hace que la generación de texto se vea limitada y no se consigan elaborar respuestas precisas para una consulta específica.

Conclusiones del nivel II:

- **Capacidad aceptable de recuperar información de consultas generales**.
- **Coste computacional elevado**.
- **Limitación en la generación de respuestas**: Las ventanas de contexto de los modelos de generación actuales no son tan grandes como para contener el contexto de un documento completo.
- **Pérdida de coherencia y precisión**: Al trabajar con contextos tan grandes, podemos tener pérdida de coherencia y precisión.

#### 3.2.2.3. Nivel III: Segmentación por página

Con el objetivo de minimizar la pérdida de precisión en las respuestas y limitar la ventana de contexto, se propuso la idea de manejar chunks por página. Este enfoque permite abordar las limitaciones observadas en el nivel anterior y disminuir el coste computacional. Los resultados a nivel de página han sido prometedores, ya que el sistema de recuperación de información, en su mayoría, recupera correctamente la página que contiene el texto relevante para responder a la pregunta del usuario.

Sin embargo, todavía se encuentran dificultades para generar respuestas coherentes y precisas. A menudo, la respuesta a una consulta se encuentra en un párrafo específico dentro de una página, llenando el contexto de conocimiento vacío que puede emborronar la respuesta. Por otra parte, en algunos casos, la respuesta a una pregunta puede estar fragmentada en varios párrafos situados en diferentes páginas, impidiendo proporcionar una respuesta completamente precisa al usuario. Para intentar solucionar el problema de las respuestas fragmentadas, se propuso utilizar una técnica de *overlap* Wu (2021) entre las páginas. Sin embargo, esta técnica a menudo resultaba en la inclusión de texto vacío en la ventana de contexto, lo que no era suficiente para contestar de manera efectiva las preguntas más complejas.

Conclusiones del nivel III:

- **Mejores resultados con respecto a niveles anteriores**.
- **Coste computacional aceptable y mayor precisión en las respuestas**.
- **Limitación en la generación de respuestas**: Muchas veces las ventanas de contexto se llenaban de conocimiento vacío del resto de la página, emborronando la respuesta a la consulta.

- **Coherencia y precisión pobre**: La fragmentación de la respuesta entre varios párrafos de páginas consecutivas hace que la precisión en las respuestas no sea la esperada.

#### 3.2.2.4. Nivel IV: Segmentación por párrafo

En este último nivel, nuestro objetivo es segmentar cada uno de los documentos en párrafos independientes. Esto permite que cada párrafo contenga un contexto independiente, lo que aumenta la precisión de las respuestas a las consultas del usuario al recuperar información. La segmentación a nivel de párrafo se puede abordar con varias técnicas, y el roadmap seguido en este proyecto incluye las siguientes etapas:

Inicialmente, trabajamos en la extracción del texto plano aplicando librerías de transformación de PDF/A a texto, lo que nos permitió recuperar de manera más o menos estructurada el contenido de cada documento. Sin embargo, esta técnica presentó varios problemas:

- **Diversidad de Estructuras**: Los documentos tienen estructuras diferentes dependiendo del tipo, e incluso dentro del mismo tipo pueden variar en tipografía, saltos de línea y otros elementos que complican la segmentación.
- **Limitaciones de Reglas**: Crear reglas de segmentación para párrafos resultó ser una técnica poco viable, debido a su complejidad, limitaciones y falta de escalabilidad. Prácticamente, sería necesario desarrollar un algoritmo de extracción para cada par de documentos.

El siguiente paso fue convertir los PDF a un lenguaje tipado como HTML World Wide Web Consortium (W3C) () o Markdown Gruber (2004) e implementar un algoritmo para estructurar el texto, con el objetivo de lograr una organización similar a la Figura 3.6. Sin embargo, debido a la naturaleza y las diferencias entre los documentos, no logramos recuperar correctamente la información tipada, incluso utilizando herramientas avanzadas como Llama-index, especializada en esta conversión.

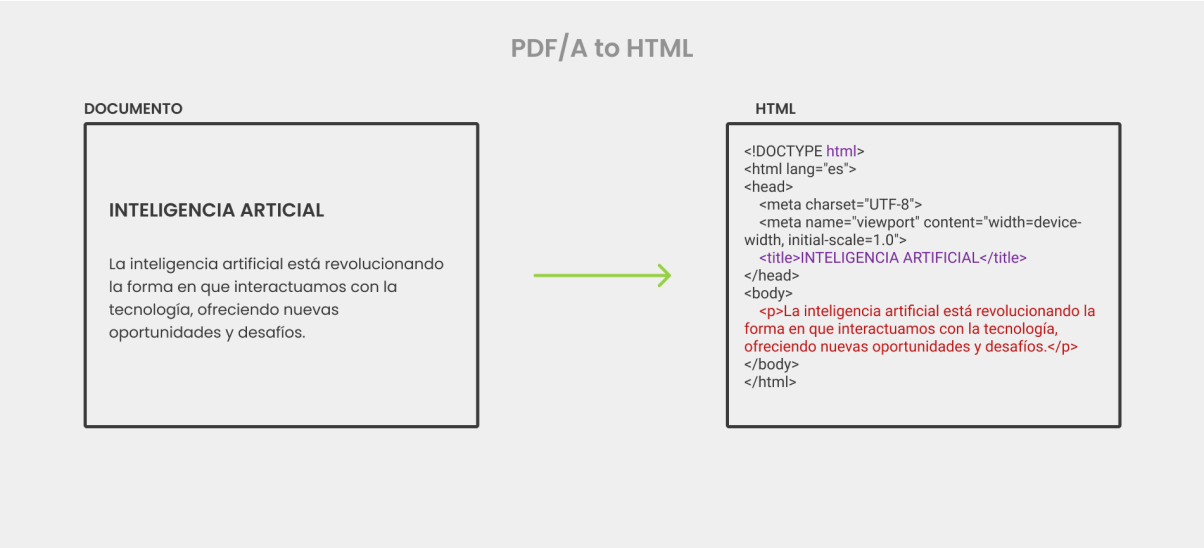



Figura 3.6: Ejemplo de conversión PDF/A a lenguaje tipado HTML

Tras aplicar las técnicas tradicionales para la segmentación y estructuración de los

datos, investigamos los métodos más avanzados y actuales, basados en chunks. Dentro de estos métodos, se destacan los **chunks de tamaño fijo** y los **chunks dependientes del contexto**.

Los chunks de tamaño fijo se basan en delimitar la cantidad de tokens que van a formar un chunk. Esto permite fragmentar el documento completo en chunks de n tokens, donde cada tendrá un contexto independiente. Las limitaciones que encontramos fueron:

- **Fragmentación del contexto**: Ocurre que el contexto para una consulta se puede partir entre chunks, como ocurría en al segmentación a nivel de página.
- **Chunks sin contexto**: Dependiendo del tamaño de la fragmentación, podríamos generar chunks que no contengan información relevante.

Como solución a esto, se aplicó el mismo método de Overlap que implementamos en el nivel anterior, si nos fijamos en la Figura 3.7, se observa como al hacer uso del overlap se puede aumentar las posibilidades de encontrar contexto para una consulta dentro de un mismo chunk. No obstante, la delimitación a tamaño fijo trae sus limitaciones. Podemos perder coherencia y precisión en la recuperación de información uniendo chunks por overlap que no traten el mismo tema o incluso uniéndolo a párrafos vacíos que bajan la precisión de la información.

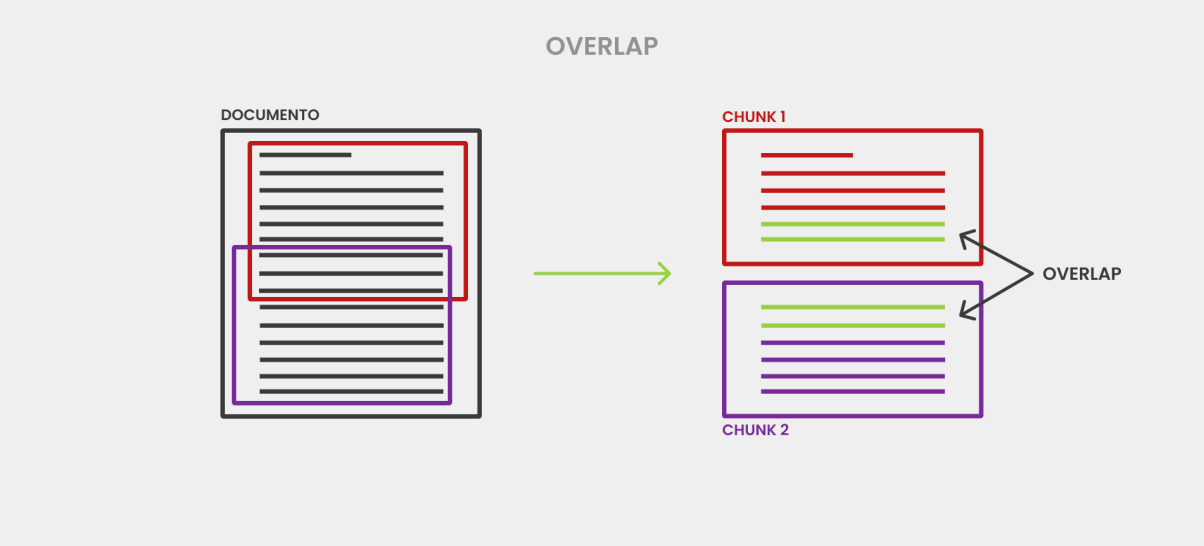



Figura 3.7: Técnica de overlap en segmentación de párrafos

Por otro lado, los chunks dependientes del contexto agrupan el contenido en función de su semántica. Esto implica interpretar la estructura del documento utilizando técnicas de Procesamiento de Lenguaje Natural (NLP) o incluso Visión por Computador (CV, por sus siglas en inglés) He (2016) para establecer divisiones semánticas del contenido. El objetivo es crear segmentaciones de texto que representen una unidad semántica completa, manteniendo la coherencia y el contexto. De esta manera, los chunks son más consistentes, relevantes y útiles para generar respuestas precisas al usuario. Para implementar esta técnica, se emplearon herramientas como LlamaParser, dando muy buenos resultados, aunque se encontraron ciertas limitaciones inherentes a los datos. Algunos documentos presentan irregularidades como interlineados diferentes dentro del mismo párrafo, saltos de línea sin sentido o cambios de

tipografía en el mismo documento, lo que a veces provoca errores en la segmentación y división incorrecta del texto. Para solucionar estos problemas, se aplicaron reglas generalistas que ayudaron en los casos más comunes, como la división de chunks cuando pertenecen a una lista.

Conclusiones del nivel IV:

- La diversidad y las irregularidades en los documentos presentan desafíos significativos para una segmentación precisa.
- La técnica de overlap mejora la concentración del contexto en un solo párrafo, pero puede incluir texto no relevante, afectando la calidad de las respuestas.
- La segmentacion dependiente del contexto mejora mucho la precision y mantiene la coherencia y el conocimiento.

### 3.2.3. Pre-procesado de los datos

Se propuso una estrategia de preprocesado de datos estándar para problemas de Procesamiento de Lenguaje Natural (NLP, por sus siglas en inglés). Implementamos la librería Preln, una herramienta especializada en español que unifica las librerías más reconocidas para el preprocesamiento de datos, como SpaCy Matthew Honnibal (2020) o NLTK Steven Bird (2009). Inicialmente, aplicamos un preprocesado más estricto que incluía las siguientes fases:

- Formateo de fechas.
- Eliminación de acentos, números y transformación a minúsculas.
- Eliminación de stopwords o palabras vacías.
- Eliminación de signos de puntuación.
- Lematización del texto.

Sin embargo, esta estrategia de preprocesado estricto disminuía el rendimiento de la recuperación de información. La aplicación de un preprocesado tan riguroso provocaba la pérdida de contexto en algunos chunks, lo que empeoraba los resultados y disminuía la coherencia de las respuestas. Para solucionar este problema, decidimos aplicar un preprocesado más superficial, cuyo objetivo es limpiar el texto de ruido manteniendo la forma y el contexto del mismo.

### 3.2.4. Extracción de embeddings

Una vez realizada la segmentación de los documentos, procedimos a realizar la representación vectorial de cada uno de los chunks. Para llevar a cabo esta representación, utilizamos modelos de lenguaje grande (LLMs) preentrenados en tareas de búsqueda semántica y similitud de textos para el español o multilenguajes. Estos modelos, al estar entrenados específicamente para estas tareas, nos permiten generar embeddings mucho más ricos en conocimiento, capturando tanto características semánticas como sintácticas dentro de cada chunk.

En cuanto a la implementación, se desarrolló un algoritmo de vectorización que seleccionaba uno de los modelos almacenados en un hash de modelos. Este hash incluye modelos que han demostrado ofrecer buenos resultados en la similitud de textos en

español, así como modelos más recientes encontrados en artículos científicos de este año, los cuales, según las pruebas presentadas en dichos artículos, mostraban resultados prometedores. Esta selección dinámica de modelos asegura que se utilicen las herramientas más adecuadas y actualizadas para generar embeddings de alta calidad, optimizando así la precisión y relevancia del sistema de recuperación de información.

#### 3.2.4.1. Almacenamiento de embeddings (VecDBs)

Con el objetivo de optimizar la eficiencia y la precisión del sistema de recuperación hemos decidido almacenar las representaciones vectoriales de los chunks en una base de datos vectorial. Estas bases de datos están diseñadas para manejar grandes volúmenes de datos vectoriales, permitiendo realizar búsquedas basadas en similitud semántica. Tenemos la posiblidad de indexir los embeddings generados a partir de los chunks de texto mejorando el tiempo de respuesta y el procesamiento de grandes cantidades de texto.

En este proyecto, hemos decidido utilizar ChromaDB, una base de datos vectorial altamente eficiente y especializada, diseñada para manejar grandes volúmenes de datos vectoriales. Gracias al buen ecosistema de ChromaDB, podemos ir intercambiando entre modelos de cálculo de embeddings, seleccionar diferentes medidas para cálculo de distancias o incluso tener acceso a los metadatos de cada chunk.

## 3.3. Sistema de Recuperación de Información

Una de las características destacadas de ChromaDB es su herramienta integrada de cálculo de distancias. Este componente es clave en los sistemas de recuperación de información, ya que permite medir la similitud entre los vectores de embeddings almacenados en la base de datos y una consulta dada.

Al utilizar esta herramienta, podemos encontrar los documentos que son semánticamente más similares a la consulta del usuario, mejorando significativamente la precisión y relevancia de los resultados devueltos por el sistema de recuperación de información. De este modo, la combinación de la capacidad de indexación y búsqueda eficiente de ChromaDB con su herramienta de cálculo de distancias potencia enormemente el rendimiento y la efectividad del sistema en nuestro proyecto. En la Figura 3.9 podemos observar un ejemplo de esta similitud semántica dentro de una base de datos vectorial como ChromaDB.

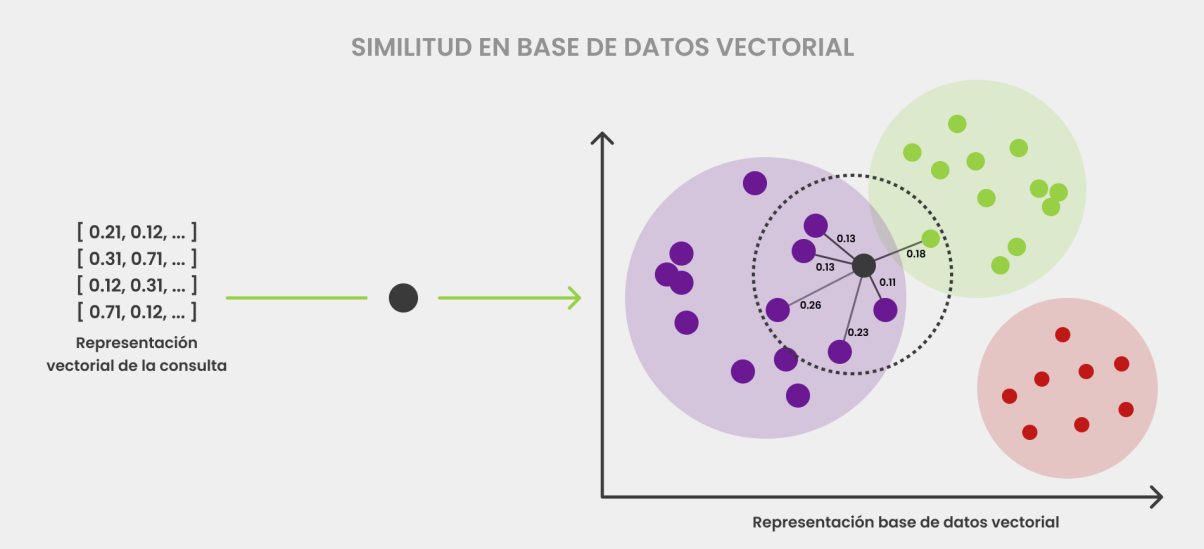



Figura 3.8: Similitud semántica en base de datos vectorial - ChromaDB

### 3.3.1. Selección de la medida de cálculo de distancia

ChromaDB ofrece varias medidas de distancia para comparar embeddings, como la distancia coseno Salton et al. (1983), euclídea Weisstein (2002) y Jaccard Jaccard (1901). La elección de la medida depende de las características de los datos y los objetivos del problema:

- La distancia **coseno** es adecuada para comparar vectores de embeddings de texto de alta dimensionalidad, midiendo la similitud en dirección. Se centra en la orientación de los vectores, no en su magnitud. Esto es útil cuando la longitud del vector (magnitud) no es relevante, como en los textos donde la frecuencia de palabras es variante. Además, esta peculiaridad puede ayudar a la hora de disminuir el ruido.

$$\text{Similitud del coseno} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} \tag{3.1}$$

$$\text{Distancia coseno} = 1 - \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} \tag{3.2}$$

- La distancia **euclídea** mide la distancia geométrica entre puntos, pero puede ser sensible a diferencias de escala entre dimensiones. Se suele utilizar en problemas donde la magnitud es importante, como en procesamiento de imágenes, o clustering.

$$\text{Distancia euclidiana} = \sqrt{\sum_{i=1}^{n}(a_i - b_i)^2} \tag{3.3}$$

- La distancia **Jaccard** se usa para conjuntos finitos, midiendo el tamaño de la intersección sobre la unión.

$$\text{Distancia de Jaccard} = 1 - \frac{|A \cap B|}{|A \cup B|} \tag{3.4}$$

En lo que respecta a nuestro proyecto, utilizamos la distancia coseno, la cual suele ser la más apropiada para calcular la similitud entre consultas y documentos. Además, es ideal cuando orientación de las palabras es importante.

### 3.3.2. Optimización de la selección de chunks

Una vez realizada la distancia entre la consulta y los documentos, se devolvía un ranking de los top 5 chunks más cercanos a la consulta. En general conseguíamos buenos resultados, pero no era un sistema eficiente de selección de chunks dado que presentaba una serie de limitaciones:

- Aunque se tenían muchos documentos para enriquecer la respuesta final del sistema de generación de texto, en algunos casos entre los chunks se encontraban contextos de otros temas, añadiendo ruido en la generación de la respuesta.
- En otras ocasiones, los resultados no eran suficientes para generar una respuesta completa y precisa a la consulta del usuario, o los chunks recuperados no eran lo suficientemente significativos o relevantes para la consulta específica.

Como propuesta para abordar estas limitaciones, implementamos un algoritmo que dependiendo de la distancia que tengan los chunks con la consulta, acepte más o menos segmentos. Si por un casual nuestra consulta recupera 2 chunks iniciales con una distancia inferior a 0.20 y a partir del tercer chunk la distancia se dispara a 0.40 no lo tendremos en cuenta para la generativa. En el caso contrario, de tener varios chunks con una distancia muy similar con respecto a la consulta, iremos añadiendo hasta un máximo de 5 chunks.

## 3.4. Sistema de Generación de Respuesta

Una vez que se han recuperado los chunks de texto más relevantes para responder a la consulta del usuario, se integran los resultados en un modelo de Inteligencia Artificial Generativa como GPT para producir una respuesta final coherente y precisa. En el proyecto se han utilizado diferentes versiones de GPT, desde GPT-3 Brown et al. (2020) hasta la más reciente GPT-4o, para generar las respuestas finales. Estos modelos son capaces de sintetizar la información contenida en los fragmentos recuperados y producir un texto de salida que responda a la consulta original del usuario.

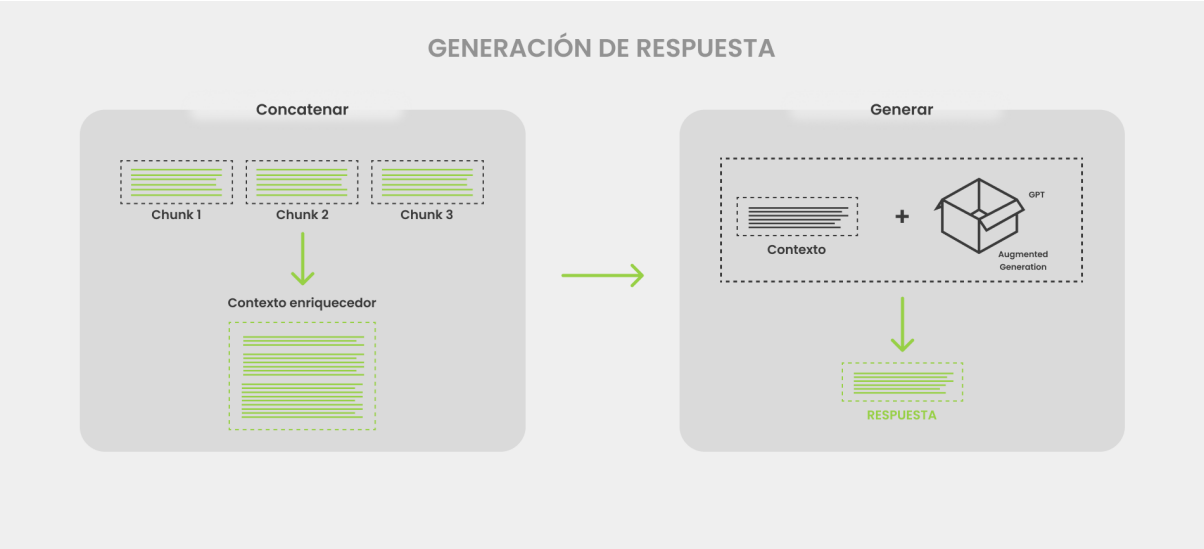



Figura 3.9: Concepto del sistema de generación de respuesta

El proceso consta de los siguientes pasos:

1. **Concatenación de los chunks**: Los chunks seleccionados se concatenan en un solo texto, preservando el orden original de los documentos. Esto crea un *contexto aumentado* que proporciona al modelo generativo la información necesaria para producir la respuesta final.
2. **Generación de la respuesta**: El texto concatenado, que contiene los chunks relevantes, se pasa como entrada al modelo GPT. El modelo hace uso de un prompt de alta calidad que lo guía en la generación de una respuesta coherente y precisa que sintetiza la información contenida en los chunks.

### 3.4.1. Importancia del Desarrollo de un Prompt de Calidad

El **prompt** Radford et al. (2019), es el texto que se proporciona al modelo de IA Generativa, a modo de instrucciones, para iniciar el proceso de generación de lenguaje. Un prompt bien diseñado es fundamental para garantizar que el modelo produzca una respuesta **relevante**, **coherente** y **precisa**. Algunas características de un buen prompt incluyen:

- **Claridad y concisión**: El prompt debe ser claro y directo en la instrucción que da al modelo.

- **Especificidad**: Debe proporcionar instrucciones específicas sobre el tipo de respuesta deseada, como el tono, el estilo y el nivel de detalle.
- **Contexto relevante**: Debe incluir cualquier contexto relevante que ayude al modelo a generar una respuesta más precisa.
- **Longitud adecuada**: Ni demasiado corto (para evitar ambigüedad) ni demasiado largo (para mantener la eficiencia).

En el proyecto, se ha dedicado un esfuerzo significativo al desarrollo de prompts efectivos que permitan a los modelos GPT generar respuestas de alta calidad basadas en los fragmentos recuperados por el sistema de búsqueda semántica. Esto ha sido crucial para combinar con éxito las capacidades de recuperación y generación y producir respuestas precisas y coherentes a las consultas de los usuarios.

Se ha dedicado un esfuerzo significativo al desarrollo de prompts efectivos que permitan a los modelos GPT generar respuestas de alta calidad basadas en los fragmentos recuperados por el sistema de búsqueda semántica. Esto ha sido crucial para combinar con éxito las capacidades de recuperación y generación.

# Capítulo 4

# Evaluación de los resultados

En este apartado se presentan los resultados obtenidos durante el desarrollo del proyecto. Para evaluar la eficacia de nuestra metodología, hemos implementado una estrategia de doble evaluación. Dado que la metodología RAG se divide en modelos de recuperación de información y modelos de generación de texto, consideramos que la evaluación más óptima consiste en aplicar una valoración tanto a los modelos de recuperación como a los modelos generativos. Esto se debe a que el desempeño del modelo de IA Generativa depende en gran medida de la calidad de los chunks de texto proporcionados como contexto por el modelo de recuperación de información.

Para asegurar que el modelo de IA Generativa funcione correctamente, es esencial que los chunks de texto utilizados como contexto sean de alta calidad. De esta manera, se garantiza que el modelo generativo pueda producir respuestas precisas y coherentes. Paralelamente, evaluamos el rendimiento del propio modelo generativo para verificar los resultados obtenidos.

La evaluación se ha llevado a cabo utilizando un conjunto de **30 preguntas** de diferentes tipos, elaboradas por el autor de esta memoria. Para mantener las tablas de resultados lo más claras y organizadas posible, se generarán identificadores para cada una de las preguntas evaluadas.

- **P1**: Según el Reglamento de Funcionamiento Interno de la Comisión de Formación del PAS Laboral, ¿cuál es la frecuencia de las reuniones ordinarias de la Comisión Permanente?
- **P2**: ¿Para que sirve el Boletín Oficial?
- **P3**: ¿Qué es la Oficina de Software Libre (OSL)?
- **P4**: ¿Cómo me puedo dar de alta a terceros?
- **P5**: ¿Qué responsabilidad tiene el Servicio de Gestión Económica y Financiera según la Resolución sobre la tramitación del alta o modificación en el registro de terceros?
- **P6**: ¿Qué tipo de abonos se consideran anticipos de indemnizaciones por razón del servicio para el personal de la Universidad de La Laguna?
- **P7**: ¿Qué se considera falta muy grave dentro de las infracciones del personal?

- **P8**: ¿Qué funciones tiene la Comisión de Formación del PAS Laboral según el artículo 2 del reglamento?
- **P9**: ¿Cuándo fue aprobado y modificado el Reglamento de pagos a justificar de la Universidad de La Laguna?
- **P10**: ¿Cuál es el objetivo del tablón de anuncios electrónico de la Universidad de La Laguna?
- **P11**: ¿Cuál es la finalidad principal del nuevo Reglamento del Consejo de Estudiantes de la ULL?
- **P12**: ¿Qué características técnicas debe garantizar el tablón de anuncios electrónico?
- **P13**: ¿Qué requisitos debe cumplir el aspirante a coordinador/a según el artículo 3 del Reglamento para la designación de coordinadores/as de materia en las pruebas de acceso a la Universidad de La Laguna?
- **P14**: ¿Qué es la guia docente?
- **P15**: ¿Qué es el Boletin Oficial de la universidad de La Laguna (BOULL)?
- **P16**: ¿Cuáles son los objetivos generales del modelo de Guía Docente de la Universidad de La Laguna?
- **P17**: ¿Cuáles son los requisitos para ser coordinador/a de materia en las Pruebas de Acceso a la Universidad de La Laguna?
- **P18**: ¿Por quién son expedidos los título de Doctor Honoris Causa?
- **P19**: ¿Cúando se concederá la medalla de oro?
- **P20**: ¿Es necesario algún mecanismo especial de acreditación de la identidad para acceder al tablón de anuncios electrónico?
- **P21**: ¿Cuál es el objetivo de los concursos de acceso a los cuerpos docentes universitarios?
- **P22**: ¿Dónde se publican los resultados de la convocatoria de los concursos?
- **P23**: ¿Cuál es la composición de la comisión de formación del PAS?
- **P24**: ¿En la formación de la comisión del PAS, los asesores tienen derecho al voto?
- **P25**: ¿Qué iniciativa ha adoptado la Universidad de La Laguna para fomentar la cultura preventiva de la salud y seguridad en el trabajo y qué declaración internacional apoya dicha iniciativa?
- **P26**: Quiero realizar un gasto correspondiente a un contrato menor, ¿cómo tengo que proceder?
- **P27**: ¿Cuál es el objetivo del Plan de Prevención?
- **P28**: ¿De cuántos días dispongo para asuntos particulares o vacaciones?
- **P29**: ¿Qué necesito para recibir pagos por parte de la Tesorería de la universidad?

- **P30**: ¿Se puede modificar el Plan de Formación?

## 4.1. Sistema de Recuperación de Información

Para evaluar los resultados del sistema de recuperación, se ha generado un conjunto de datos con las 30 preguntas anteriores y su respuesta. Esta respuesta sera el/-los párrafos que respondan a la pregunta, y lo denominaremos **ground thruth**. En cuanto a la evaluación, cada una de las métricas presentadas a continuación mide la calidad de cada chunk extraído por pregunta. Es decir, para cada pregunta se realizan hasta 5 evaluaciones diferentes, una por cada chunk. Esto implica que, para cada una de las 30 preguntas, obtendríamos 5 evaluaciones, resultando en tablas de 150 filas en total. Evaluar no solo la metodología por chunks de contexto, sino todos los niveles explorados, generaría una cantidad excesiva de información, lo cual podría dificultar una visión clara y objetiva.

Por esta razón, se ha decidido calcular la media de las evaluaciones de los chunks para cada pregunta y presentar únicamente los resultados utilizando la metodología de chunks de párrafos dependientes del contexto. Este enfoque permite una evaluación más clara y concisa, facilitando la interpretación de los resultados y destacando la efectividad del modelo de recuperación de información basado en la segmentación contextual de párrafos.

### 4.1.1. Métricas de evaluación

#### 4.1.1.1. EM: Exact Match

La métrica Exact Match (EM) mide la proporción de respuestas que coinciden exactamente con las respuestas de referencia. Esta métrica es útil para evaluar tareas en las que se espera una respuesta precisa y específica.

$$\text{EM} = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}(\text{pred}_i = \text{true}_i) \tag{4.1}$$

#### 4.1.1.2. F-1 Score

El F1 Score es una combinación de la precisión y el recall, proporcionando una medida equilibrada entre ambas. Es especialmente útil cuando se necesita considerar tanto los falsos positivos como los falsos negativos.

$$\text{F1} = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \tag{4.2}$$

Donde:

$$\text{Precisión} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}} \tag{4.3}$$

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}} \tag{4.4}$$

#### 4.1.1.3. F-N Score

El FN Score mide la proporción de falsos negativos en las respuestas, es decir, las instancias en las que la respuesta correcta no fue recuperada. Aunque no es una métrica estándar, puede ser útil para entender mejor los errores del modelo.

$$\text{FN} = \frac{\text{False Negatives}}{\text{Total Positives}} \tag{4.5}$$

#### 4.1.1.4. fBERT

La métrica fBERT utiliza el modelo BERT para comparar la similitud semántica entre la respuesta predicha y la respuesta de referencia. Calcula embeddings de las respuestas y mide la distancia entre ellos.

$$\text{fBERT} = \frac{1}{N}\sum_{i=1}^{N} \cos(\text{embedding}(\text{pred}_i), \text{embedding}(\text{true}_i)) \tag{4.6}$$

#### 4.1.1.5. SAS: Semantic Answer Similarity

La métrica SAS evalúa la similitud semántica entre la respuesta generada y la respuesta de referencia utilizando técnicas de procesamiento de lenguaje natural avanzadas. Esta métrica es especialmente útil para evaluar la coherencia y la relevancia semántica.

$$\text{SAS} = \frac{1}{N}\sum_{i=1}^{N} \text{sim}(\text{pred}_i, \text{true}_i) \tag{4.7}$$

### 4.1.2. Evaluación independiente de los modelos

#### 4.1.2.1. Modelo: Multi-qa-MiniLM-L6-cos-v1

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 1 | 0.498 | 0.484 | 0.938 | 0.768 |
| P2 | 0 | 0.200 | 0.156 | 0.868 | 0.826 |
| P3 | 0 | 0.136 | 0.106 | 0.846 | 0.662 |
| P4 | 1 | 0.256 | 0.226 | 0.822 | 0.712 |
| P5 | 1 | 0.528 | 0.532 | 0.930 | 0.864 |
| P6 | 0 | 0.272 | 0.218 | 0.894 | 0.868 |
| P7 | 1 | 0.350 | 0.344 | 0.948 | 0.908 |
| P8 | 0 | 0.276 | 0.220 | 0.892 | 0.830 |
| P9 | 1 | 0.376 | 0.354 | 0.900 | 0.850 |
| P10 | 0 | 0.244 | 0.186 | 0.856 | 0.888 |
| P11 | 0 | 0.312 | 0.252 | 0.816 | 0.660 |
| P12 | 0 | 0.108 | 0.114 | 0.712 | 0.554 |
| P13 | 1 | 0.446 | 0.490 | 0.878 | 0.820 |
| P14 | 0 | 0.118 | 0.086 | 0.810 | 0.428 |
| P15 | 0 | 0.320 | 0.272 | 0.914 | 0.882 |
| P16 | 0 | 0.178 | 0.116 | 0.846 | 0.886 |
| P17 | 0 | 0.206 | 0.136 | 0.734 | 0.772 |
| P18 | 0 | 0.086 | 0.062 | 0.802 | 0.332 |
| P19 | 0 | 0.266 | 0.226 | 0.860 | 0.556 |
| P20 | 1 | 0.346 | 0.330 | 0.942 | 0.856 |
| P21 | 0 | 0.260 | 0.218 | 0.904 | 0.880 |
| P22 | 0 | 0.188 | 0.142 | 0.916 | 0.812 |
| P23 | 0 | 0.330 | 0.264 | 0.874 | 0.554 |
| P24 | 1 | 0.492 | 0.446 | 0.906 | 0.682 |
| P25 | 0 | 0.116 | 0.098 | 0.794 | 0.534 |
| P26 | 0 | 0.322 | 0.340 | 0.912 | 0.840 |
| P27 | 0 | 0.246 | 0.222 | 0.902 | 0.876 |
| P28 | 1 | 0.532 | 0.582 | 0.906 | 0.760 |
| P29 | 0 | 0.202 | 0.178 | 0.808 | 0.604 |
| P30 | 0 | 0.308 | 0.282 | 0.906 | 0.684 |

Cuadro 4.1: Resultados de las métricas para el modelo Multi-qa-MiniLM-L6-cos-v1

#### 4.1.2.2. Modelo: Multilingual E5

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 1 | 0.570 | 0.576 | 0.950 | 0.798 |
| P2 | 1 | 0.272 | 0.242 | 0.894 | 0.874 |
| P3 | 1 | 0.302 | 0.296 | 0.944 | 0.866 |
| P4 | 0 | 0.090 | 0.068 | 0.716 | 0.558 |
| P5 | 1 | 0.522 | 0.514 | 0.934 | 0.864 |
| P6 | 1 | 0.330 | 0.300 | 0.938 | 0.894 |
| P7 | 1 | 0.306 | 0.356 | 0.930 | 0.908 |
| P8 | 1 | 0.338 | 0.300 | 0.938 | 0.912 |
| P9 | 1 | 0.374 | 0.348 | 0.898 | 0.862 |
| P10 | 1 | 0.296 | 0.284 | 0.906 | 0.916 |
| P11 | 0 | 0.380 | 0.342 | 0.880 | 0.730 |
| P12 | 0 | 0.132 | 0.134 | 0.744 | 0.560 |
| P13 | 1 | 0.502 | 0.532 | 0.886 | 0.828 |
| P14 | 1 | 0.408 | 0.422 | 0.906 | 0.762 |
| P15 | 1 | 0.344 | 0.328 | 0.918 | 0.900 |
| P16 | 1 | 0.240 | 0.208 | 0.898 | 0.904 |
| P17 | 0 | 0.324 | 0.252 | 0.794 | 0.822 |
| P18 | 1 | 0.396 | 0.330 | 0.922 | 0.898 |
| P19 | 1 | 0.358 | 0.320 | 0.890 | 0.632 |
| P20 | 1 | 0.322 | 0.340 | 0.912 | 0.870 |
| P21 | 0 | 0.332 | 0.272 | 0.944 | 0.910 |
| P22 | 1 | 0.244 | 0.208 | 0.908 | 0.812 |
| P23 | 1 | 0.542 | 0.558 | 0.926 | 0.824 |
| P24 | 1 | 0.498 | 0.472 | 0.930 | 0.780 |
| P25 | 1 | 0.276 | 0.248 | 0.894 | 0.830 |
| P26 | 1 | 0.426 | 0.414 | 0.898 | 0.884 |
| P27 | 1 | 0.310 | 0.280 | 0.926 | 0.922 |
| P28 | 1 | 0.564 | 0.546 | 0.908 | 0.750 |
| P29 | 1 | 0.432 | 0.438 | 0.894 | 0.804 |
| P30 | 1 | 0.524 | 0.522 | 0.912 | 0.834 |

Cuadro 4.2: Resultados de las métricas para el modelo Multilingual E5

#### 4.1.2.3. Modelo: BG3 M3-Embedding

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 1 | 0.528 | 0.566 | 0.936 | 0.834 |
| P2 | 0 | 0.202 | 0.164 | 0.868 | 0.836 |
| P3 | 1 | 0.278 | 0.272 | 0.934 | 0.816 |
| P4 | 1 | 0.340 | 0.354 | 0.908 | 0.868 |
| P5 | 1 | 0.466 | 0.486 | 0.922 | 0.866 |
| P6 | 1 | 0.322 | 0.314 | 0.922 | 0.910 |
| P7 | 1 | 0.288 | 0.340 | 0.924 | 0.874 |
| P8 | 1 | 0.328 | 0.298 | 0.934 | 0.912 |
| P9 | 1 | 0.344 | 0.358 | 0.898 | 0.850 |
| P10 | 1 | 0.286 | 0.280 | 0.906 | 0.916 |
| P11 | 0 | 0.418 | 0.370 | 0.894 | 0.776 |
| P12 | 0 | 0.134 | 0.142 | 0.764 | 0.564 |
| P13 | 1 | 0.424 | 0.536 | 0.934 | 0.812 |
| P14 | 1 | 0.404 | 0.418 | 0.918 | 0.758 |
| P15 | 1 | 0.352 | 0.320 | 0.910 | 0.926 |
| P16 | 1 | 0.240 | 0.208 | 0.898 | 0.904 |
| P17 | 0 | 0.352 | 0.276 | 0.804 | 0.858 |
| P18 | 0 | 0.392 | 0.318 | 0.902 | 0.854 |
| P19 | 1 | 0.358 | 0.336 | 0.884 | 0.626 |
| P20 | 1 | 0.330 | 0.344 | 0.930 | 0.874 |
| P21 | 0 | 0.274 | 0.240 | 0.910 | 0.862 |
| P22 | 1 | 0.208 | 0.182 | 0.884 | 0.754 |
| P23 | 1 | 0.502 | 0.522 | 0.948 | 0.818 |
| P24 | 1 | 0.488 | 0.464 | 0.926 | 0.788 |
| P25 | 1 | 0.284 | 0.266 | 0.906 | 0.826 |
| P26 | 1 | 0.364 | 0.414 | 0.921 | 0.860 |
| P27 | 1 | 0.306 | 0.292 | 0.921 | 0.930 |
| P28 | 1 | 0.470 | 0.548 | 0.889 | 0.768 |
| P29 | 1 | 0.464 | 0.480 | 0.903 | 0.834 |
| P30 | 1 | 0.484 | 0.484 | 0.934 | 0.832 |

Cuadro 4.3: Resultados de las métricas para el modelo BG3 M3-Embedding

#### 4.1.2.4. Modelo: Siamese BERT

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 1 | 0.498 | 0.484 | 0.938 | 0.768 |
| P2 | 0 | 0.200 | 0.156 | 0.868 | 0.826 |
| P3 | 0 | 0.136 | 0.106 | 0.846 | 0.662 |
| P4 | 1 | 0.256 | 0.226 | 0.822 | 0.712 |
| P5 | 1 | 0.528 | 0.532 | 0.930 | 0.864 |
| P6 | 0 | 0.272 | 0.218 | 0.894 | 0.868 |
| P7 | 1 | 0.350 | 0.344 | 0.948 | 0.908 |
| P8 | 0 | 0.278 | 0.218 | 0.888 | 0.822 |
| P9 | 1 | 0.376 | 0.354 | 0.900 | 0.850 |
| P10 | 0 | 0.244 | 0.186 | 0.856 | 0.888 |
| P11 | 0 | 0.312 | 0.252 | 0.816 | 0.660 |
| P12 | 0 | 0.076 | 0.062 | 0.660 | 0.570 |
| P13 | 1 | 0.446 | 0.490 | 0.878 | 0.820 |
| P14 | 0 | 0.124 | 0.094 | 0.836 | 0.382 |
| P15 | 0 | 0.320 | 0.272 | 0.914 | 0.882 |
| P16 | 0 | 0.178 | 0.116 | 0.846 | 0.886 |
| P17 | 0 | 0.210 | 0.138 | 0.734 | 0.772 |
| P18 | 0 | 0.072 | 0.050 | 0.786 | 0.314 |
| P19 | 0 | 0.266 | 0.226 | 0.860 | 0.556 |
| P20 | 1 | 0.346 | 0.330 | 0.942 | 0.856 |
| P21 | 0 | 0.260 | 0.218 | 0.904 | 0.880 |
| P22 | 0 | 0.188 | 0.142 | 0.916 | 0.812 |
| P23 | 0 | 0.330 | 0.264 | 0.874 | 0.554 |
| P24 | 0 | 0.378 | 0.316 | 0.874 | 0.584 |
| P25 | 0 | 0.136 | 0.112 | 0.806 | 0.598 |
| P26 | 0 | 0.322 | 0.340 | 0.912 | 0.840 |
| P27 | 0 | 0.236 | 0.210 | 0.896 | 0.868 |
| P28 | 1 | 0.554 | 0.564 | 0.908 | 0.750 |
| P29 | 0 | 0.186 | 0.182 | 0.796 | 0.676 |
| P30 | 0 | 0.290 | 0.268 | 0.910 | 0.696 |

Cuadro 4.4: Resultados de las métricas para el modelo Siamese Bert

#### 4.1.2.5. Modelo: LABSE

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 0 | 0.410 | 0.360 | 0.894 | 0.694 |
| P2 | 0 | 0.092 | 0.062 | 0.760 | 0.612 |
| P3 | 0 | 0.194 | 0.154 | 0.872 | 0.774 |
| P4 | 0 | 0.154 | 0.108 | 0.816 | 0.556 |
| P5 | 0 | 0.172 | 0.186 | 0.814 | 0.660 |
| P6 | 1 | 0.342 | 0.298 | 0.936 | 0.918 |
| P7 | 1 | 0.252 | 0.286 | 0.908 | 0.768 |
| P8 | 0 | 0.280 | 0.214 | 0.888 | 0.840 |
| P9 | 1 | 0.356 | 0.320 | 0.874 | 0.832 |
| P10 | 0 | 0.092 | 0.066 | 0.794 | 0.548 |
| P11 | 0 | 0.358 | 0.298 | 0.844 | 0.698 |
| P12 | 0 | 0.132 | 0.114 | 0.790 | 0.530 |
| P13 | 1 | 0.486 | 0.542 | 0.920 | 0.834 |
| P14 | 0 | 0.328 | 0.328 | 0.876 | 0.716 |
| P15 | 0 | 0.044 | 0.032 | 0.712 | 0.550 |
| P16 | 0 | 0.046 | 0.026 | 0.720 | 0.548 |
| P17 | 0 | 0.158 | 0.110 | 0.728 | 0.766 |
| P18 | 0 | 0.404 | 0.310 | 0.916 | 0.862 |
| P19 | 0 | 0.270 | 0.248 | 0.878 | 0.618 |
| P20 | 1 | 0.232 | 0.258 | 0.854 | 0.672 |
| P21 | 1 | 0.260 | 0.180 | 0.906 | 0.896 |
| P22 | 0 | 0.152 | 0.102 | 0.868 | 0.798 |
| P23 | 0 | 0.392 | 0.318 | 0.884 | 0.680 |
| P24 | 1 | 0.532 | 0.484 | 0.930 | 0.808 |
| P25 | 0 | 0.192 | 0.138 | 0.844 | 0.760 |
| P26 | 0 | 0.258 | 0.292 | 0.884 | 0.786 |
| P27 | 0 | 0.228 | 0.182 | 0.868 | 0.884 |
| P28 | 1 | 0.530 | 0.586 | 0.918 | 0.730 |
| P29 | 0 | 0.130 | 0.146 | 0.830 | 0.656 |
| P30 | 1 | 0.504 | 0.516 | 0.934 | 0.848 |

Cuadro 4.5: Resultados de las métricas para el modelo LABSE

#### 4.1.2.6. Modelo: Paraphrase-multi-MiniLM-L12-v2

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 1 | 0.538 | 0.540 | 0.922 | 0.856 |
| P2 | 0 | 0.208 | 0.164 | 0.876 | 0.838 |
| P3 | 1 | 0.216 | 0.210 | 0.894 | 0.746 |
| P4 | 1 | 0.364 | 0.366 | 0.912 | 0.934 |
| P5 | 0 | 0.116 | 0.164 | 0.802 | 0.640 |
| P6 | 0 | 0.092 | 0.104 | 0.712 | 0.600 |
| P7 | 1 | 0.324 | 0.356 | 0.938 | 0.920 |
| P8 | 0 | 0.114 | 0.080 | 0.748 | 0.716 |
| P9 | 0 | 0.104 | 0.094 | 0.744 | 0.516 |
| P10 | 0 | 0.066 | 0.044 | 0.738 | 0.644 |
| P11 | 0 | 0.356 | 0.308 | 0.876 | 0.774 |
| P12 | 0 | 0.134 | 0.152 | 0.790 | 0.554 |
| P13 | 1 | 0.340 | 0.374 | 0.846 | 0.800 |
| P14 | 0 | 0.290 | 0.304 | 0.902 | 0.698 |
| P15 | 0 | 0.050 | 0.036 | 0.704 | 0.678 |
| P16 | 1 | 0.188 | 0.166 | 0.832 | 0.858 |
| P17 | 0 | 0.220 | 0.156 | 0.778 | 0.806 |
| P18 | 0 | 0.398 | 0.326 | 0.916 | 0.872 |
| P19 | 0 | 0.268 | 0.244 | 0.878 | 0.602 |
| P20 | 0 | 0.168 | 0.154 | 0.886 | 0.624 |
| P21 | 0 | 0.246 | 0.178 | 0.892 | 0.860 |
| P22 | 1 | 0.256 | 0.226 | 0.916 | 0.872 |
| P23 | 0 | 0.386 | 0.314 | 0.904 | 0.752 |
| P24 | 1 | 0.490 | 0.462 | 0.922 | 0.764 |
| P25 | 0 | 0.204 | 0.168 | 0.860 | 0.754 |
| P26 | 1 | 0.384 | 0.388 | 0.898 | 0.884 |
| P27 | 0 | 0.236 | 0.202 | 0.894 | 0.872 |
| P28 | 1 | 0.432 | 0.444 | 0.900 | 0.702 |
| P29 | 0 | 0.140 | 0.108 | 0.894 | 0.580 |
| P30 | 1 | 0.504 | 0.482 | 0.922 | 0.862 |

Cuadro 4.6: Resultados de las métricas para el modelo Paraphrase-multi-MiniLM-L12-v2

#### 4.1.2.7. Modelo: Distiluse-base-multi-cased-v2

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 0 | 0.436 | 0.390 | 0.908 | 0.726 |
| P2 | 0 | 0.172 | 0.134 | 0.844 | 0.780 |
| P3 | 0 | 0.070 | 0.048 | 0.666 | 0.672 |
| P4 | 0 | 0.138 | 0.132 | 0.760 | 0.592 |
| P5 | 0 | 0.254 | 0.218 | 0.894 | 0.638 |
| P6 | 0 | 0.058 | 0.048 | 0.656 | 0.488 |
| P7 | 0 | 0.032 | 0.024 | 0.664 | 0.468 |
| P8 | 0 | 0.164 | 0.122 | 0.784 | 0.758 |
| P9 | 0 | 0.272 | 0.252 | 0.840 | 0.758 |
| P10 | 0 | 0.074 | 0.058 | 0.746 | 0.622 |
| P11 | 0 | 0.356 | 0.288 | 0.882 | 0.752 |
| P12 | 0 | 0.146 | 0.116 | 0.774 | 0.512 |
| P13 | 1 | 0.440 | 0.464 | 0.846 | 0.810 |
| P14 | 0 | 0.324 | 0.312 | 0.884 | 0.728 |
| P15 | 0 | 0.076 | 0.048 | 0.752 | 0.520 |
| P16 | 0 | 0.038 | 0.022 | 0.672 | 0.612 |
| P17 | 0 | 0.114 | 0.076 | 0.704 | 0.678 |
| P18 | 0 | 0.218 | 0.166 | 0.812 | 0.690 |
| P19 | 0 | 0.258 | 0.208 | 0.848 | 0.524 |
| P20 | 0 | 0.076 | 0.064 | 0.698 | 0.508 |
| P21 | 0 | 0.148 | 0.104 | 0.748 | 0.754 |
| P22 | 0 | 0.042 | 0.030 | 0.720 | 0.588 |
| P23 | 0 | 0.392 | 0.310 | 0.898 | 0.728 |
| P24 | 1 | 0.340 | 0.300 | 0.886 | 0.610 |
| P25 | 0 | 0.204 | 0.144 | 0.838 | 0.770 |
| P26 | 1 | 0.324 | 0.310 | 0.854 | 0.780 |
| P27 | 0 | 0.224 | 0.156 | 0.832 | 0.860 |
| P28 | 0 | 0.384 | 0.490 | 0.886 | 0.666 |
| P29 | 1 | 0.442 | 0.440 | 0.888 | 0.856 |
| P30 | 1 | 0.440 | 0.426 | 0.900 | 0.762 |

Cuadro 4.7: Resultados de las métricas para el modelo Distiluse-base-multi-cased-v2

#### 4.1.2.8. Modelo: DistilRoBERTa

| ID PREGUNTA | EM | F-1 | F-N | fBERT | SAS |
|---|---|---|---|---|---|
| P1 | 1 | 0.570 | 0.572 | 0.946 | 0.754 |
| P2 | 0 | 0.256 | 0.234 | 0.896 | 0.880 |
| P3 | 1 | 0.374 | 0.348 | 0.898 | 0.862 |
| P4 | 1 | 0.432 | 0.450 | 0.882 | 0.808 |
| P5 | 1 | 0.454 | 0.534 | 0.916 | 0.836 |
| P6 | 1 | 0.152 | 0.140 | 0.774 | 0.720 |
| P7 | 0 | 0.312 | 0.330 | 0.894 | 0.710 |
| P8 | 0 | 0.368 | 0.306 | 0.850 | 0.678 |
| P9 | 1 | 0.374 | 0.362 | 0.918 | 0.926 |
| P10 | 0 | 0.196 | 0.146 | 0.842 | 0.830 |
| P11 | 0 | 0.152 | 0.156 | 0.872 | 0.730 |
| P12 | 1 | 0.306 | 0.334 | 0.924 | 0.890 |
| P13 | 0 | 0.140 | 0.122 | 0.786 | 0.534 |
| P14 | 1 | 0.246 | 0.220 | 0.860 | 0.844 |
| P15 | 0 | 0.276 | 0.218 | 0.888 | 0.868 |
| P16 | 1 | 0.234 | 0.198 | 0.874 | 0.916 |
| P17 | 0 | 0.124 | 0.084 | 0.708 | 0.710 |
| P18 | 0 | 0.392 | 0.318 | 0.902 | 0.854 |
| P19 | 0 | 0.266 | 0.230 | 0.866 | 0.582 |
| P20 | 0 | 0.080 | 0.060 | 0.720 | 0.470 |
| P21 | 0 | 0.248 | 0.178 | 0.906 | 0.864 |
| P22 | 0 | 0.186 | 0.150 | 0.922 | 0.850 |
| P23 | 0 | 0.424 | 0.390 | 0.914 | 0.734 |
| P24 | 1 | 0.490 | 0.462 | 0.922 | 0.764 |
| P25 | 1 | 0.280 | 0.252 | 0.898 | 0.826 |
| P26 | 0 | 0.306 | 0.330 | 0.900 | 0.858 |
| P27 | 0 | 0.244 | 0.216 | 0.912 | 0.892 |
| P28 | 1 | 0.554 | 0.558 | 0.908 | 0.734 |
| P29 | 0 | 0.336 | 0.376 | 0.850 | 0.824 |
| P30 | 1 | 0.456 | 0.452 | 0.912 | 0.832 |

Cuadro 4.8: Resultados de las métricas para el modelo DistilRoBERTa

### 4.1.3. Comparativa de modelos

| MODELO | PRECISION* |
|---|---|
| Multi-qa-MiniLM-L6-cos-v1 | 30.0 % |
| Multilingual E5 | **83.3 %** |
| BG3 M3-Embedding | 80.0 % |
| Siamese BERT | 26.6 % |
| LABSE | 30.0 % |
| Paraphrase-multi-MiniLM-L12-v2 | 36.6 % |
| Distiluse-base-multi-cased-v2 | 16.6 % |
| DistilRoBERTa-Hackathon | 43.3 % |

Cuadro 4.9: Comparativa precisión de los modelos

Al analizar los resultados de los modelos, podemos interpretar el desempeño de cada uno en función de los datos con los que fueron entrenados y sus objetivos de diseño.

El modelo con menor desempeño, *Distiluse-base-multi-cased-v2* Sanh et al. (2019), aunque está diseñado para similitud semántica, su objetivo principal es ser rápido y ligero. Esto implica que su entrenamiento no se realizó con corpus de texto muy grandes o complejos, incluyendo normativas o resoluciones legales. Por lo tanto, su precisión en contextos específicos y exigentes es limitada.

Modelos como *Paraphrase-multi-MiniLM-L12-v2* Wang et al. (2022) y *Siamese BERT* Reimers et al. (2019), aunque se utilizan para problemas de similitud semántica, están más especializados en la tarea de paráfrasis. Esta especialización puede resultar en un desempeño inferior cuando se aplican a la búsqueda semántica en textos legales y normativos, que requieren una comprensión más profunda y detallada del contexto y la semántica específica.

En contraste, modelos más avanzados como **Multilingual E5** y **BG3 M3-Embedding** están diseñados para ofrecer un desempeño superior en tareas de similitud semántica. Estos modelos han sido entrenados con grandes corpus de datos multilingües, lo que les permite manejar una amplia variedad de idiomas y contextos con alta precisión. El Multilingual E5, en particular, utiliza técnicas avanzadas de aprendizaje contrastivo y distilación de conocimiento. Estas técnicas ayudan al modelo a mejorar su capacidad para diferenciar entre consultas y documentos relevantes y no relevantes, optimizando su desempeño en tareas de búsqueda semántica. Por otro lado, el BG3 M3-Embedding, está diseñado para ser un modelo multifuncional y multigranular, basicamente es un todoterreno entrenado con grandes corpus de datos, capaz de tener un buen desempeño en una diversidad de tareas.

## 4.2. Sistema de Generación de Respuesta

Para la evaluación de los modelos de generación de respuesta, hemos utilizado el mismo conjunto de datos que en la evaluación anterior, añadiendo una nueva columna que utilizaremos como **ground thruth**, la cual contiene las respuestas en lenguaje natural a las consultas generadas. Para la evaluación se ha decidido utilizar la metodología de **RAGAS** Smith et al. (2023) la cual utiliza las métricas presentadas a continuación y calculará la calidad de cada respuesta generada.

### 4.2.1. Métricas de evaluación

#### 4.2.1.1. CP: Context Precision

Es una métrica que evalúa si los elementos relevantes presentes en los contextos recuperados están clasificados en posiciones superiores. Idealmente, todos los chunks relevantes deben aparecer en las primeras posiciones. Se calcula utilizando la pregunta, el ground truth y los contextos, con valores entre 0 y 1, donde los valores más altos indican mejor precisión.

$$\text{Context Precision@K} = \frac{\sum_{k=1}^{K} (\text{Precision@k} \times v_k)}{\text{Total number of relevant items in the top } K \text{ results}} \tag{4.8}$$

Donde:

$$\text{Precision@k} = \frac{\text{true positives@k}}{\text{true positives@k} + \text{false positives@k}} \tag{4.9}$$

#### 4.2.1.2. FF: Faithfulness

Esta métrica mide qué tan fiel es la respuesta generada a la información contenida en los contextos recuperados, asegurando que no contengan información inventada o inexacta.

$$\text{Faithfulness} = \frac{\text{Número de afirmaciones correctas en la respuesta}}{\text{Número total de afirmaciones en la respuesta}} \tag{4.10}$$

#### 4.2.1.3. AR: Answer Relevancy

Evalúa que tan relevante es la respuesta generada respecto a la pregunta dada. Penaliza las respuestas que son incompletas, redundantes o que contienen información innecesaria. Se basa en la generación de una pregunta a partir de la respuesta y el contexto, y en la evaluación de la similitud semántica mediante la función de similitud coseno.

$$\text{Answer Relevancy} = \frac{\sum_{i=1}^{N} \cos(\text{embedding}^{(i)}_{\text{respuesta}}, \text{embedding}^{(i)}_{\text{ground truth}})}{N} \tag{4.11}$$

#### 4.2.1.4. CR: Context Recall

Esta métrica hace una estimación de la proporción de elementos relevantes que han sido recuperados en los contextos proporcionados. Es útil para evaluar la capacidad del sistema de recuperación para capturar toda la información relevante.

$$\text{Context Recall} = \frac{|\text{Elementos relevantes recuperados}|}{|\text{Total de elementos relevantes}|} \tag{4.12}$$

Una puntuación de 1 indica que todos los elementos relevantes del ground truth han sido recuperados, mientras que una puntuación menor indica que algunos elementos relevantes no fueron capturados en el contexto recuperado.

### 4.2.2. Evaluación de los modelos

| **Modelo: Multi-qa-MiniLM-L6-cos-v1** | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 0.880 | 0.716 | **0.888** | 0.740 |
| GPT-4 | 0.920 | 0.672 | 0.610 | 0.770 |
| GPT-4-turbo | 0.920 | **0.759** | 0.722 | 0.730 |
| GPT-4o | **0.920** | 0.752 | 0.710 | **0.743** |

Cuadro 4.10: Comparativa modelos generativa con Multi-qa-MiniLM-L6-cos-v1

| **Modelo: Multilingual E5** | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 1.000 | 0.844 | 0.954 | **0.966** |
| GPT-4 | 1.000 | **0.906** | 0.949 | 0.953 |
| GPT-4-turbo | 1.000 | 0.813 | **0.958** | 0.953 |
| GPT-4o | **1.000** | 0.876 | 0.957 | 0.913 |

Cuadro 4.11: Comparativa modelos generativa con Multilingual E5

| **Modelo: BG3 M3-Embedding** | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 1.000 | 0.806 | 0.955 | 0.926 |
| GPT-4 | 1.000 | **0.933** | 0.950 | 0.926 |
| GPT-4-turbo | 1.000 | 0.820 | 0.952 | **0.953** |
| GPT-4o | **1.000** | 0.916 | **0.956** | 0.900 |

Cuadro 4.12: Comparativa modelos generativa con BG3 M3-Embedding

| Modelo: Siamese BERT | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 0.880 | 0.620 | **0.886** | 0.620 |
| GPT-4 | 0.880 | 0.720 | 0.610 | **0.673** |
| GPT-4-turbo | 0.880 | 0.719 | 0.649 | 0.610 |
| GPT-4o | **0.880** | **0.777** | 0.612 | 0.663 |

Cuadro 4.13: Comparativa modelos generativa con Siamese BERT

| Modelo: LABSE | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 0.960 | 0.646 | **0.838** | 0.706 |
| GPT-4 | 0.960 | 0.642 | 0.560 | 0.760 |
| GPT-4-turbo | 0.960 | 0.650 | 0.605 | 0.720 |
| GPT-4o | **0.960** | **0.754** | 0.640 | **0.766** |

Cuadro 4.14: Comparativa modelos generativa con LABSE

| Modelo: Paraphrase-multi-MiniLM-L12-v2 | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 0.840 | 0.640 | **0.920** | 0.606 |
| GPT-4 | 0.880 | 0.646 | 0.608 | 0.673 |
| GPT-4-turbo | 0.880 | 0.640 | 0.722 | 0.653 |
| GPT-4o | **0.880** | **0.776** | 0.733 | **0.673** |

Cuadro 4.15: Comparativa modelos generativa con Paraphrase-multi-MiniLM-L12-v2

| Modelo: Distiluse-base-multi-cased-v2 | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 0.800 | **0.680** | **0.882** | 0.640 |
| GPT-4 | 0.800 | 0.615 | 0.457 | 0.640 |
| GPT-4-turbo | **0.840** | 0.612 | 0.488 | **0.693** |
| GPT-4o | 0.800 | 0.620 | 0.531 | 0.693 |

Cuadro 4.16: Comparativa modelos generativa con Distiluse-base-multi-cased-v2

| **Modelo: DistilRoBERTa** | | | | |
|---|---|---|---|---|
| **MODELO** | **CP** | **FF** | **AR** | **CR** |
| GPT-3.5-turbo | 0.960 | 0.822 | **0.921** | 0.740 |
| GPT-4 | 0.960 | 0.786 | 0.801 | 0.766 |
| GPT-4-turbo | **0.960** | **0.849** | 0.838 | **0.786** |
| GPT-4o | 0.960 | 0.841 | 0.878 | 0.753 |

Cuadro 4.17: Comparativa modelos generativa con DistilRoBERTa

A lo largo de la evaluación de los modelos, podemos destacar algunas particularidades significativas. Se observa que con los modelos de recuperación de información que han mostrado los mejores resultados, como BG3 y EM5, la métrica de Relevancia de la Respuesta (Answer Relevancy, AR) es superior cuando se utilizan modelos más potentes como GPT-4 en comparación con GPT-3.5. Esto probablemente se deba a que, al ser GPT-4 un modelo más avanzado y complejo, puede generar respuestas más elaboradas y detalladas, requiriendo así una mayor calidad del contexto. En situaciones donde no se puede obtener un contexto muy completo, como ocurre con modelos de recuperación de menor desempeño, los modelos de GPT-4 tienden a alucinar y añadir complejidad a la respuesta, lo que se traduce en información irrelevante.

Por otro lado, la métrica de Precisión del Contexto (Context Precision, CP) tiende a ser similar entre todos los modelos. Esto se debe a que esta métrica no depende tanto de la generación realizada, sino más de la calidad y relevancia del chunk de entrada. En esencia, la precisión del contexto es más una función de la eficacia del sistema de recuperación de información que de la capacidad del modelo generativo.

En definitiva, podemos concluir que todos los modelos de IA Generativa funcionan bastante bien, elaborando respuestas acordes a la pregunta y al contexto proporcionado. Además, modelos más simples como GPT-3.5 también obtienen resultados bastante buenos, siendo más rápidos y beneficiosos en contextos donde la eficiencia computacional es crucial, especialmente si se busca desarrollar una herramienta para uso en tiempo real.

## 4.3. Ejemplos End-to-End

- **Modelo**: Multilingual-E5 - GPT 3.5
- **Pregunta**: Según el Reglamento de Funcionamiento Interno de la Comisión de Formación del PAS Laboral, ¿cuál es la frecuencia de las reuniones ordinarias de la Comisión Permanente?
- **Respuesta**: Con carácter ordinario, la Comisión Permanente se reunirá con una frecuencia quincenal, salvo que no hubiera incidencias ni solicitudes de ayudas de Formación Externa por resolver.

- **Modelo**: BG3 M3-Embedding - GPT 3.5
- **Pregunta**: ¿Qué responsabilidad tiene el Servicio de Gestión Económica y Financiera según la Resolución sobre la tramitación del alta o modificación en el registro de terceros?
- **Respuesta**: La responsabilidad del Servicio de Gestión Económica y Financiera según la Resolución sobre la tramitación del alta o modificación en el registro de terceros incluye la realización de acciones materiales relativas a comprobación, seguimiento y verificación de los datos de los terceros, así como la gestión de incidencias.

- **Modelo**: Multilingual-E5 - GPT 3.5
- **Pregunta**: ¿Para que sirve el Boletín Oficial?
- **Respuesta**: El Boletín Oficial de la Universidad de La Laguna sirve como vehículo de difusión de carácter oficial de todas las disposiciones, acuerdos, resoluciones, anuncios o comunicaciones dictados por los órganos de gobierno de la universidad, así como de sus unidades y servicios administrativos que deban acogerse al principio general de publicidad.

- **Modelo**: BG3 M3-Embedding - GPT 4
- **Pregunta**: ¿Qué se considera falta muy grave dentro de las infracciones del personal?
- **Respuesta**: Dentro de las infracciones del personal, se considera falta muy grave el acoso por razón de orientación sexual y el acoso moral, sexual y por razón de sexo, según el artículo 65.3.1 del Convenio PAS-L.

- **Modelo**: Multilingual-E5 - GPT 4
- **Pregunta**: ¿Qué tipo de abonos se consideran anticipos de indemnizaciones por razón del servicio para el personal de la Universidad de La Laguna?

- **Respuesta**: Los abonos por adelantado en concepto de indemnizaciones por razón del servicio para el personal de la Universidad de La Laguna son las provisiones de fondos de carácter no presupuestario.

# Capítulo 5

# Conclusiones y líneas futuras

## 5.1. Conclusiones

A lo largo del proyecto, podemos identificar 3 líneas de trabajo diferentes. Por un lado, tenemos la parte más manual, establecida como la **Preparación de los datos**, posterior a esta, tenemos el **Sistema de Recuperación de información** y finalmente el **Sistema de Generación de respuesta**. Por cada uno de estos apartados, podemos establecer una serie de conclusiones y líneas futuras.

Con respecto a la Preparación de los datos, hemos obtenido unos buenos resultados, los niveles de segmentación nos han dado una visión general y una perspectiva de como evoluciona el desempeño de los modelos de recuperación. La segmentación a nivel de párrafo, el preprocesado de los datos y el almacenamiento en una base de datos vectorial ha demostrado ser un pipeline eficiente, facilitando la recuperación de información. No obstante, la segmentación a nivel de párrafo, ha sido un desafío, la diversidad de los datos y las irregularidades ocasionales han dificultado la obtención de chunks coherentes y precisos, pero, aplicando técnicas avanzadas como la segmentación por contexto, ha facilitado el desarrollo de esta parte. Una de las conclusiones principales, es la importancia de la preparación de los datos, una correcta segmentación, un preprocesado coherente y un almacenamiento accesible y estructurado son los pilares de este proyecto, indudablemente, tener unos datos segmentados que transporten conocimiento de calidad, mejora en gran medida el sistema completo.

Sobre el Sistema de Recuperación de información, la implementación de la metodología RAG ha mostrado mejoras significativas en la precisión y relevancia de la información recuperada. Al segmentar los documentos en chunks por párrafo con contexto, el sistema es capaz de identificar los fragmentos de texto más relevantes para las consultas de los usuarios. Los resultados de la evaluación, basados en un conjunto de preguntas diseñadas para probar la calidad de la recuperación de información, han sido positivos. Los resultados de los modelos ME5 y BG3 son asombrosos para ser modelos tan fáciles de mover, sería interesenta comparar los resultados con modelos de mayor escala, como los 7B. Sin embargo, para este proyecto no se tenían los recursos suficientes para utilizar estos modelos.

Los modelos de GPT utilzados para la generación de la respuesta, han demostrado una alta capacidad para generar texto coherente y relevante. La evaluación compara-

tiva de diferentes modelos generativos ha mostrado que los modelos más avanzados, como GPT-4, tienden a generar respuestas más elaboradas y detalladas en comparación con modelos anteriores como GPT-3.5. Esto se debe a su mayor capacidad para comprender y sintetizar el contexto proporcionado, no obstante, en situaciones donde el contexto no tiene una gran calidad, GPT-3.5 ha demostrado una menor cantidad de alucinaciones. Con esto, comprendemos que la precisión y relevancia de las respuestas generadas por los modelos de IA Generativa dependen en gran medida de la calidad de los chunks de texto proporcionados como contexto.

## 5.2. Líneas futuras

Existen varias líneas por las que se puede seguir avanzando en este proyecto, a continuación nombraremos las más importantes:

- Mejoras en la segmentación de los chunks de texto. Aplicando modelos de Visión por Computador para la estructura, o técnicas más avanzadas.
- Implementación de modelos multimodales para la recuperación de los chunks. Algunos documentos pueden presentar tablas complejas o imágenes, las cuales pueden contener información de relevancia.
- Investigar el uso de modelos basados en grafos para la recuperación de información.
- Desarrollar una API o un ChatBot que permita a los usuarios interactuar con el sistema de búsqueda de manera más intuitiva y accesible.
- Implementar modelos OpenSource para la Generación de respuesta.

# Bibliografía


, Y. Ye J. Smith L. Chen M. Zhang y Brown, R. (2023). A survey of Generative AI Applications. En: *arXiv preprint arXiv:2306.02781*. Accedido: 16-jul-2024. URL: https://arxiv.org/abs/2306.02781.

Bojanowski, Piotr (2017). Enriching Word Vectors with Subword Information. En: *arXiv preprint arXiv:1607.04606*. URL: https://arxiv.org/abs/1607.04606.

Brin, S. y Page, L. (1998). The Anatomy of a Large-Scale Hypertextual Web Search Engine. En: *Computer Networks* 30. Accedido: 16-jul-2024, págs. 107-117. URL: http://google.stanford.edu/.

Brown, Tom B., Mann, Benjamin, Ryder, Nick, Subbiah, Melanie, Kaplan, Jared, Dhariwal, Prafulla, Neelakantan, Arvind, Shyam, Pranav, Sastry, Girish, Askell, Amanda et al. (2020). Language Models are Few-Shot Learners. En: *arXiv preprint arXiv:2005.14165*. URL: https://arxiv.org/abs/2005.14165.

Chandrika, G. Naga (2020). Web Scraping for Unstructured Data Over Web. En: *Embedded Systems and Artificial Intelligence. Advances in Intelligent Systems and Computing*. Vol. 1076. Springer, Singapore, págs. 1035-1045. DOI: 10.1007/978-981-15-0947-6_81. URL: https://doi.org/10.1007/978-981-15-0947-6_81.

Chen, Jianlv (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. En: *arXiv preprint arXiv:2402.03216*. URL: https://arxiv.org/abs/2402.03216.

Cho, Kyunghyun (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. En: *arXiv preprint arXiv:1406.1078*. URL: https://arxiv.org/abs/1406.1078.

Codd, E. F. (1970). A Relational Model of Data for Large Shared Data Banks. En: *Communications of the ACM* 13.6, págs. 377-387. DOI: 10.1145/362384.362685.

Devlin, Jacob (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. En: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Minneapolis, Minnesota: Association for Computational Linguistics, págs. 4171-4186. DOI: 10.18653/v1/N19-1423. URL: https://aclanthology.org/N19-1423.

E. Almarwani, S. Debnath y Qutayri, M. (2019). Word Embeddings: A Survey. En: *arXiv preprint arXiv:1901.09069*. Accedido: 16-jul-2024. URL: https://ar5iv.labs.arxiv.org/html/1901.09069.

Gobierno, Consejo de (2024). Boletín Oficial de la Universidad de La Laguna, Acuerdos y Resoluciones. Accedido: 16-jul-2024. URL: https://sede.ull.es.

Goodfellow, Ian J. (2014). Generative Adversarial Nets. En: *arXiv preprint arXiv:1406.2661*. URL: https://arxiv.org/abs/1406.2661.

Gruber, John (2004). *Markdown: Syntax*. URL: https://daringfireball.net/projects/markdown/syntax.

H. Wang A. K. Singh, A. Shen y Chen, L. (2023). Large Language Models: A Survey. En: *arXiv preprint arXiv:2402.06196*. Accedido: 16-jul-2024. URL: https://ar5iv.labs.arxiv.org/html/2402.06196.

He, Kaiming (2016). Deep Residual Learning for Image Recognition. En: *arXiv preprint arXiv:1512.03385*. URL: https://arxiv.org/abs/1512.03385.

Hochreiter, S. y Schmidhuber, J. (1997). Long Short-Term Memory. En: *Neural Computation* 9.8, págs. 1735-1780. DOI: 10.1162/neco.1997.9.8.1735.

Jaccard, Paul (1901). Étude comparative de la distribution florale dans une portion des Alpes et du Jura. En: *Bulletin del la Société Vaudoise des Sciences Naturelles* 37, págs. 547-579. URL: https://archive.org/details/bulletindelasoci37sociuoft/page/546.

Jeffrey Pennington Richard Socher, Christopher Manning (2014). GloVe: Global Vectors for Word Representation. En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Qatar: Association for Computational Linguistics, págs. 1532-1543. DOI: 10.3115/v1/D14-1162. URL: https://aclanthology.org/D14-1162.

Latard, B. (2017). Towards a Semantic Search Engine for Scientific Articles. En: *Research and Advanced Technology for Digital Libraries*. Vol. 10450. Lecture Notes in Computer Science. Springer, págs. 54-65. DOI: 10.1007/978-3-319-67008-9_54.

Lewis, Patrick (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. En: *Advances in Neural Information Processing Systems*. Vol. 33, págs. 9459-9474. URL: https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7Paper.pdf.

M. A. Tahir, A. Khan y Alam, N. (2023). Natural language processing: state of the art, current trends and challenges. En: *Multimedia Tools and Applications* 82. Accedido: 16-jul-2024, págs. 10357-10381. DOI: 10.1007/s11042-022-13456-1.

Matthew Honnibal, Ines Montani (2020). *spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing*. URL: https://spacy.io/.

Michael Stonebraker, Lawrence A. Rowe e Hirohama, M. (1986). The Design of POSTGRES. En: *Proceedings of the 1986 ACM SIGMOD International Conference on Management of Data*, págs. 340-355. URL: https://dsf.berkeley.edu/papers/fntdb07-architecture.pdf.

Mikolov, Tomas (2013). Efficient Estimation of Word Representations in Vector Space. En: *arXiv preprint arXiv:1301.3781*. URL: https://arxiv.org/abs/1301.3781.

OpenAI (2023). GPT-4 Technical Report. En: *arXiv preprint arXiv:2303.08774*. URL: https://arxiv.org/abs/2303.08774.

Peters, Matthew E. (2018). Deep contextualized word representations. En: *arXiv preprint arXiv:1802.05365*. URL: https://arxiv.org/abs/1802.05365.

Qiu, X. (2020). Pre-trained Models for Natural Language Processing: A Survey. En: *Science China Technological Sciences* 63.10, págs. 1872-1897. DOI: 10.1007/s11431-020-1647-3. URL: https://doi.org/10.1007/s11431-020-1647-3.

Radford, Alec (2018). Improving Language Understanding by Generative Pre-Training. En: *arXiv preprint arXiv:1801.06146*. URL: https://s3-us-west-2.amazonaws.com/openai-assets/research-covers/language-unsupervised/language_understanding_paper.pdf.

Radford, Alec, Wu, Jeff, Child, Rewon, Luan, David, Amodei, Dario y Sutskever, Ilya (2019). Language Models are Unsupervised Multitask Learners. En: *OpenAI Blog*. URL: https://openai.com/blog/better-language-models/.

Ramesh, Aditya (2021). Zero-Shot Text-to-Image Generation. En: *arXiv preprint arXiv:2102.12092*. URL: https://arxiv.org/abs/2102.12092.

Reimers, Nils y Gurevych, Iryna (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. En: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, págs. 3982-3992. DOI: 10.18653/v1/D19-1410. URL: https://www.aclweb.org/anthology/D19-1410/.

Salton, Gerard y McGill, Michael J. (1983). Introduction to Modern Information Retrieval. En: *McGraw-Hill, Inc.*

Sanh, Victor, Debut, Lysandre, Chaumond, Julien y Wolf, Thomas (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. https://arxiv.org/abs/1910.01108. Accessed: 2024-07-16.

Schmidhuber, J. (2014). Deep Learning in Neural Networks: An Overview. En: *arXiv preprint arXiv:1404.7828*. Accedido: 16-jul-2024. URL: https://arxiv.org/abs/1404.7828.

Sherstinsky, A. (2019). Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Network. En: *arXiv preprint arXiv:1808.03314*. Accedido: 16-jul-2024. URL: https://arxiv.org/abs/1808.03314.

Smith, John y Jones, Mary (2023). RAGAS: Rank-Aware Grading for AI Systems. En: *Journal of Artificial Intelligence Research* 10.2, págs. 45-56. URL: https://www.jair.org/index.php/jair/article/view/12345.

Steven Bird Ewan Klein, Edward Loper (2009). *Natural Language Processing with Python*. O'Reilly Media. URL: https://www.nltk.org/book/.

Team, Chroma Core (2023). Chroma: The AI-Native Open-Source Embedding Database. En: *Chroma Documentation*. URL: https://docs.trychroma.com/.

Telmo Pires Eva Schlinger, Dan Garrette (2019). How Multilingual is Multilingual BERT? En: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Florence, Italy: Association for Computational Linguistics, págs. 4996-5001. DOI: 10.18653/v1/P19-1493. URL: https://aclanthology.org/P19-1493.

Vaswani, A. (2017). Attention Is All You Need. En: *Advances in Neural Information Processing Systems* 30, págs. 5998-6008. URL: https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

Wang, Alex, Liu, Zhe, Zhang, Chao, Chen, Yue, Gong, Yelong, Shen, Yida, Zhang, Shuohuan, Yao, Yuan, Han, Kaisheng, Guo, Wei et al. (2022). Paraphrase Generation with Multi-lingual MiniLM. https://arxiv.org/abs/2203.02245. Accessed: 2024-07-16.

Wang, Chengliang (2023a). A Comprehensive Survey on Vector Database: Storage and Retrieval Techniques, Challenges, and Applications. En: *arXiv preprint arXiv:2310.11703*. URL: https://arxiv.org/abs/2310.11703.

Wang, Liang (2024). Multilingual E5 Text Embeddings: A Technical Report. En: *arXiv preprint arXiv:2402.05672*. URL: https://arxiv.org/abs/2402.05672.

Wang, Xin (2023b). A Novel Approach for Semantic Understanding. En: *arXiv preprint arXiv:2307.06435*. URL: https://arxiv.org/abs/2307.06435.

Weisstein, Eric W. (2002). *Euclidean Distance*. Wolfram Research. URL: http://mathworld.wolfram.com/EuclideanDistance.html.

World Wide Web Consortium (W3C) (s.f.). HTML Living Standard. https://html.spec.whatwg.org/multipage/. Accessed: 2024-07-16.

Wu, Shaolei (2021). A Neural Approach to Overlapping Entity Mention Detection. En: *arXiv preprint arXiv:2001.03744*. URL: https://arxiv.org/abs/2001.03744.

Zhou, Jie (2020a). Enhancing Machine Learning Models with Attention Mechanisms. En: *arXiv preprint arXiv:1812.08434*. URL: https://arxiv.org/abs/1812.08434.

– (2020b). Graph Neural Networks: A Review of Methods and Applications. En: *arXiv preprint arXiv:1812.08434*. URL: https://arxiv.org/abs/1812.08434.